

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ
ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(национальный исследовательский университет)»

Институт (Филиал) №8 «Компьютерные науки и прикладная математика»
Кафедра 806
Группа М8О-403Б-22
Направление подготовки 01.03.02 Прикладная математика и информатика

Профиль Информатика

Квалификация бакалавр

УТВЕРЖДАЮ

Заведующий кафедрой №806 _____ С. С.

Крылов

(№ каф.)

(подпись)

(инициалы, фамилия)

_____ 2026 г.

ЗАДАНИЕ

на выпускную квалификационную работу бакалавра

Обучающийся Мудров Павел Федорович
(фамилия, имя, отчество полностью)

Руководитель Ляпина Светлана Юрьевна
(фамилия, имя, отчество полностью)

профессор

ученая степень, ученое звание, должность и место работы)

1. Наименование темы RL в прогнозировании временных рядов
2. Срок сдачи обучающимся законченной работы N.0N.2026

3. Задание и исходные данные к работе

Разработать экспериментальный стенд для исследования применения методов обучения с подкреплением к прогнозированию временных рядов, включая сравнение baseline-, ML-, DL- и RL-подходов на нескольких компактных датасетах.

Перечень иллюстративно-графических материалов *при наличии.

№ п/п	Наименование	Количество листов
-------	--------------	-------------------

4. Перечень подлежащих разработке разделов и этапы выполнения работы

№ п/п	Наименование раздела или этапа	Трудоемкость в % от полной трудоемкости квалификационной работы	Срок выполнения	Примечание
1	Аналитический обзор методов прогнозирования временных рядов и RL-подходов	15	15.02.2026	
2	Постановка задачи forecasting и проектирование RL-селектора моделей	15	26.02.2026	
3	Программная реализация experimental pipeline, baseline- и neural-моделей	45	20.03.2026	
4	Проведение сравнительного тестирования методов по качеству и вычислительным затратам	15	01.04.2026	

5	Формирование выводов, ограничений исследования и направлений дальнейшего развития	10	15.04.2026	
---	---	----	------------	--

5 Исходные материалы и пособия

Hyndman R. J., Athanasopoulos G. Forecasting: Principles and Practice – URL: <https://otexts.com/fpp3/> (дата обращения 27.04.2026)

Mnih V., Kavukcuoglu K., Silver D. et al. Human-level Control through Deep Reinforcement Learning // Nature, 2015

Stable-Baselines3 Documentation: DQN, PPO – URL: <https://stable-baselines3.readthedocs.io/> (дата обращения 27.04.2026)

PyTorch Documentation; Gymnasium API; statsmodels Documentation – URL: <https://pytorch.org/>, <https://gymnasium.farama.org/>, <https://www.statsmodels.org/> (дата обращения 27.04.2026)

6. Дата выдачи задания 11.02.2026

Руководитель
(подпись)

Задание принял к исполнению

(подпись)

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ
ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(национальный исследовательский университет)»

Институт (Филиал) №8 «Компьютерные науки и прикладная математика»

Кафедра 806

Группа М8О-403Б-22

Направление подготовки 01.03.02 Прикладная математика и информатика

Профиль Информатика

Квалификация бакалавр

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
БАКАЛАВРА

На тему: «RL в прогнозировании временных рядов»

Автор ВКРБ _____ Мудров Павел Федорович
(_____)

(фамилия, имя, отчество полностью)
Руководитель Ляпина Светлана Юрьевна (_____) (фамилия, имя, отчество полностью)

Консультант (_____) (фамилия, имя, отчество полностью)

Консультант (_____) (фамилия, имя, отчество полностью)

Рецензент (_____) (фамилия, имя, отчество полностью)

К защите допустить

Заведующий кафедрой № 806 _____ Крылов Сергей Сергеевич
(_____) (№ каф) (фамилия,
имя, отчество полностью)
_____ 2026 г.

Москва 2026
МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ
ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(национальный исследовательский университет)»

СПИСОК ИСПОЛНИТЕЛЕЙ

Мудров Павел Федорович — введение, раздел 1, раздел 2, раздел 3, раздел 4,
заключение, приложение А

О Т З Ы В РУКОВОДИТЕЛЯ

Обучающийся Мудров Павел Федорович
(фамилия, имя, отчество полностью)
Институт (Филиал) _____ №8 «Компьютерные науки и прикладная математика»

Кафедра 806
Группа М8О-403Б-22
Направление подготовки 01.03.02 Прикладная математика и информатика
Профиль Информатика

Кваліфікація бакалавр

Наименование темы	RL в прогнозировании временных рядов
-------------------	--------------------------------------

Руководитель Ляпина Светлана Юрьевна
(фамилия, имя, отчество полностью, ученая степень, ученое звание,
должность и место работы)
профессор

2026 г.

Руководитель _____ (подпись)

РЕФЕРАТ

Черновик выпускной квалификационной работы бакалавра состоит из 58 страниц, 20 использованных источников, 6 таблиц, 6 рисунков и 1 приложения

ВРЕМЕННЫЕ РЯДЫ, ПРОГНОЗИРОВАНИЕ, ОБУЧЕНИЕ С ПОДКРЕПЛЕНИЕМ, НЕСТАЦИОНАРНОСТЬ, DQN, PPO, ВЫБОР МОДЕЛИ, АНСАМБЛИРОВАНИЕ, ARIMA, LIGHTGBM, LSTM

Целью работы является исследование применимости методов обучения с подкреплением к задаче прогнозирования временных рядов в качестве адаптивного механизма выбора модели и управления ансамблем. В работе рассматривается проблема снижения качества прогноза при изменении структуры временного ряда, смене режима, появлении тренда, сезонности и изменении волатильности.

В рамках исследования выполнен аналитический обзор классических статистических методов, методов машинного обучения, нейросетевых архитектур и RL-подходов, применимых к прогнозированию временных рядов. Предлагается постановка задачи, в которой обучение с подкреплением используется не как полная замена forecasting-модели, а как надстройка над ансамблем заранее обученных моделей, принимающая последовательные решения на временной оси.

Практическая часть ориентирована на воспроизводимый запуск на ноутбуке класса MacBook M3 Pro с 18 GB RAM. Для этого рассматриваются компактные конфигурации моделей, временное разбиение train/validation/test без перемешивания, а также ограниченный набор реальных и учебных датасетов. В качестве основных метрик используются MAE, RMSE, MAPE, sMAPE и MASE [3]; дополнительно анализируются время обучения и время инференса.

Основной результат состоит в том, что RL-подход целесообразно рассматривать как адаптивный слой над базовыми прогнозирующими моделями. В проведенном стендовом исследовании на небольших датасетах DQN-селектор не продемонстрировал устойчивого превосходства над лучшей отдельной моделью, однако позволил формализовать задачу динамического выбора модели и показать, в каких условиях RL-подход может быть полезен, а в каких приводит лишь к росту вычислительных затрат.

СОДЕРЖАНИЕ

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ	7
ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ	8
ВВЕДЕНИЕ	9
1 АНАЛИТИЧЕСКИЙ ОБЗОР МЕТОДОВ ПРОГНОЗИРОВАНИЯ ВРЕМЕННЫХ РЯДОВ	12
1.1 Особенности временных рядов	12
1.2 Классические baseline-методы	15
1.3 Методы машинного обучения	18
1.4 Нейросетевые методы	20
1.5 Применение обучения с подкреплением к прогнозированию	23
1.6 Вывод по разделу	26
2 ПОСТАНОВКА ЗАДАЧИ И ПРОЕКТИРОВАНИЕ МЕТОДА	27
2.1 Формальная постановка задачи прогнозирования	27
2.2 Постановка RL-задачи	29
2.3 DQN-селектор моделей	31
2.4 PPO-подход к взвешиванию ансамбля	32
2.5 Метрики качества и ресурсные ограничения	33
2.6 Вывод по разделу	34
3 РЕАЛИЗАЦИЯ ЭКСПЕРИМЕНТАЛЬНОГО СТЕНДА	35
3.1 Архитектура программного решения	35
3.2 Загрузка и предобработка данных	36
3.3 Генерация признаков и baseline-модели	37
3.4 Нейросетевые модели и RL-среда	39
3.5 Организация экспериментов и сохранение результатов	40
3.6 Вывод по разделу	41
4 ЭКСПЕРИМЕНТАЛЬНОЕ ИССЛЕДОВАНИЕ	42
4.1 Датасеты и схема эксперимента	42
4.2 Сравнение классических методов	43
4.3 Сравнение ML- и DL-моделей	45
4.4 Анализ RL-подхода	47
4.5 Сравнение по вычислительным затратам	49

4.6 Итоги экспериментов	50
ЗАКЛЮЧЕНИЕ	51
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	53
ПРИЛОЖЕНИЕ А	55

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ

В настоящей выпускной квалификационной работе применяют следующие термины с соответствующими определениями:

Временной ряд — упорядоченная по времени последовательность наблюдений, отражающая изменение изучаемого показателя

Нестационарность — свойство временного ряда, при котором его статистические характеристики изменяются во времени

Прогнозирование временного ряда — задача оценки будущих значений ряда на основе исторических наблюдений и, при необходимости, дополнительных признаков

Горизонт прогнозирования — число шагов вперед, на которое формируется прогноз

Лаговый признак — значение временного ряда, сдвинутое на фиксированное число шагов назад относительно текущего момента времени

Скользящее среднее — статистика локального усреднения ряда по окну фиксированной длины

Ансамбль моделей — совокупность нескольких прогнозирующих моделей, результаты которых выбираются или агрегируются по заданному правилу

Обучение с подкреплением — парадигма машинного обучения, в которой агент последовательно выбирает действия в среде и получает награду за их последствия [12], [14]

Состояние агента — вектор признаков, описывающий доступную агенту информацию в текущий момент времени

Функция награды — правило количественной оценки качества выбранного действия агента

DQN (Deep Q-Network) — алгоритм глубокого Q-обучения, аппроксимирующий функцию ценности действий нейронной сетью [12]

PPO (Proximal Policy Optimization) — алгоритм градиентной оптимизации политики с ограничением величины обновления [13]

Concept drift — изменение закономерностей данных во времени, приводящее к ухудшению качества ранее обученной модели

MASE — масштабированная средняя абсолютная ошибка, позволяющая сравнивать качество прогноза на разных рядах [3]

ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ

В настоящей выпускной квалификационной работе применяют следующие сокращения и обозначения:

ИИ — искусственный интеллект

МО — машинное обучение

НС — нейронная сеть

RL — reinforcement learning, обучение с подкреплением

DL — deep learning, глубокое обучение

MLP — multilayer perceptron, многослойный перцептрон

LSTM — long short-term memory

GRU — gated recurrent unit
DQN — deep Q-network
PPO — proximal policy optimization
MAE — mean absolute error
RMSE — root mean squared error
MAPE — mean absolute percentage error
sMAPE — symmetric mean absolute percentage error
MASE — mean absolute scaled error
MPS — Metal Performance Shaders

ВВЕДЕНИЕ

Задачи прогнозирования временных рядов имеют высокую практическую значимость в финансовой аналитике, энергетике, логистике, метеорологии, управлении промышленными системами и ряде других областей. Во многих прикладных сценариях от качества прогноза зависит своевременность управленческих решений, устойчивость процессов и стоимость ошибок. При этом реальные временные ряды редко являются полностью стационарными: меняются тренд, сезонность, амплитуда колебаний, появляются аномальные режимы и структурные сдвиги. Именно поэтому проблема адаптации моделей к изменяющимся данным остается одной из ключевых в современной теории и практике прогнозирования.

Классические статистические методы, такие как экспоненциальное сглаживание, Holt-Winters и ARIMA/SARIMA, сохраняют практическую ценность благодаря интерпретируемости и низкой вычислительной стоимости [1], [2]. Однако при смене режима временного ряда их качество может ухудшаться, особенно если параметры модели фиксированы и не пересматриваются оперативно. Аналогичная проблема возникает и у методов машинного обучения, и у нейросетевых моделей: даже если модель хорошо обучена на исторических данных, изменение распределения может привести к росту ошибки на валидации и тесте.

Современные методы глубокого обучения, включая LSTM, GRU, DLinear, N-BEATS и компактные Transformer-архитектуры, способны извлекать более сложные зависимости [4]–[8], [11]. Тем не менее повышение выразительной способности модели не гарантирует автоматической адаптивности во времени. Чем сложнее модель, тем выше риск переобучения на небольших выборках и тем выше требования к вычислительным ресурсам. Для учебно-исследовательского проекта, ориентированного на локальный запуск на потребительском ноутбуке, чрезмерно тяжелые архитектуры часто оказываются неэффективными.

В данной работе рассматривается идея использования обучения с подкреплением не как прямой замены модели прогнозирования, а как адаптивного механизма поверх уже обученного ансамбля. Такой подход позволяет трактовать прогнозирование как последовательный процесс принятия решений: в каждый момент времени агент наблюдает состояние ряда и качество отдельных моделей на последних шагах, после чего выбирает модель, прогноз которой следует использовать. В более общем варианте агент может не только выбирать одну модель, но и подбирать веса ансамбля или корректировать базовый прогноз.

Актуальность темы определяется несколькими обстоятельствами. Во-первых, временные ряды во многих практических задачах нестационарны. Во-вторых, большинство традиционных моделей оптимизируются на фиксированной обучающей выборке и затем применяются без адаптивного механизма управления. В-третьих, RL естественным образом формулирует задачу адаптации как задачу последовательного выбора действий в изменяющейся среде [12], [14]. Наконец, для исследовательской ценности важно не только продемонстрировать возможные преимущества RL, но и показать ограничения его применения по сравнению с более простыми и дешевыми по вычислительной стоимости методами.

Целью выпускной квалификационной работы является разработка и исследование экспериментального подхода к прогнозированию временных рядов, в котором обучение с подкреплением используется для адаптивного выбора модели из ансамбля и, как расширение, для динамического взвешивания ансамбля. Для достижения поставленной цели необходимо решить следующие задачи:

- 1) Выполнить аналитический обзор классических, ML-, DL- и RL-подходов к прогнозированию временных рядов;
- 2) Сформулировать задачу прогнозирования и RL-задачу в единой экспериментальной постановке;
- 3) Спроектировать программный стенд с временным разбиением данных, генерацией признаков и единым интерфейсом моделей;
- 4) Реализовать и сравнить baseline-модели, методы машинного обучения, компактные нейросетевые модели и RL-DQN селектор моделей;
- 5) Оценить качество подходов по метрикам прогноза, времени обучения и времени инференса;
- 6) Проанализировать, в каких условиях RL-подход действительно полезен, а в каких уступает лучшей отдельной модели или простому ансамблю.

Объектом исследования являются методы прогнозирования временных рядов в условиях ограниченных вычислительных ресурсов и потенциальной нестационарности данных. Предметом исследования являются алгоритмы адаптивного управления прогнозом на основе истории ошибок моделей и текущего состояния ряда.

Практическая значимость работы состоит в том, что предложенный подход может использоваться как модуль над существующим forecasting-конвейером без полной замены базовых моделей. Такой способ интеграции RL особенно важен в случаях, когда в системе уже доступны несколько моделей с различными индуктивными предпосылками, а задача состоит в их динамическом согласовании.

Структура работы включает введение, четыре главы, заключение, список использованных источников и приложение. В первой главе рассматриваются теоретические и методические основы прогнозирования временных рядов и применения RL. Во второй главе формулируется постановка задачи и предлагается целевой метод. В третьей главе описывается программная реализация экспериментального стенда. В четвертой главе приводятся результаты вычислительных экспериментов и их интерпретация.

1 АНАЛИТИЧЕСКИЙ ОБЗОР МЕТОДОВ ПРОГНОЗИРОВАНИЯ

ВРЕМЕННЫХ РЯДОВ

1.1 Особенности временных рядов

Временной ряд отличается от произвольной табличной выборки тем, что наблюдения зависят от порядка следования по времени. Нарушение временной структуры, например случайное перемешивание строк, приводит к разрушению причинно-временных зависимостей и делает постановку прогноза некорректной. Поэтому для задач forecasting принципиально важны упорядоченность, лаговые зависимости, возможная сезонность и наличие автокорреляции [1], [2].

С практической точки зрения временные ряды можно рассматривать как результат наложения нескольких компонент: тренда, сезонной составляющей, циклических колебаний, шума и редких аномальных событий. Одни модели ориентированы на явное разложение ряда на компоненты, другие пытаются аппроксимировать зависимость напрямую. Выбор метода зависит от длины ряда, частоты измерений, горизонта прогноза и допускаемой вычислительной стоимости.

1.1.1 Структура временного ряда и источники неопределенности

Даже в простых прикладных примерах временной ряд редко подчиняется одной неизменной закономерности. Пассажиропоток может содержать тренд роста и сезонность; финансовый ряд — резкие скачки и смену волатильности; погодные данные — локальные циклы и шум датчиков. Следовательно, модель прогноза должна либо быть достаточно устойчивой к этим эффектам, либо сопровождаться адаптивным механизмом перенастройки.

Неопределенность в задаче прогнозирования возникает из нескольких источников. Во-первых, далеко не все факторы, влияющие на ряд, наблюдаемы. Во-вторых, оценка параметров строится по конечной и шумной выборке. В-третьих, распределение данных может изменяться уже после завершения обучения. Для малых и средних выборок эта проблема особенно заметна, так как даже несколько нехарактерных участков могут существенно повлиять на оценку модели.

1.1.2 Нестационарность, смена режимов и concept drift

Одной из центральных проблем прогнозирования является нестационарность. Если математическое ожидание, дисперсия и корреляционная структура ряда изменяются во времени, то модель, обученная на старой части выборки, перестает быть оптимальной на новой части. В статистических моделях это проявляется в неустойчивости коэффициентов, а в нейронных моделях — в ухудшении обобщающей способности на тестовом интервале.

В прикладной литературе изменение свойств данных нередко описывается также термином concept drift. С практической точки зрения это означает, что оптимальная стратегия прогнозирования в момент времени t может отличаться от стратегии, оптимальной в момент $t + h$. Следовательно, статически выбранная модель не всегда способна обеспечивать минимальную ошибку на всем временном интервале.

Именно здесь возникает мотивация для применения RL. Если лучшая модель

меняется во времени, то задачу можно рассматривать не как разовую процедуру обучения фиксированного прогноза, а как последовательность решений о выборе наиболее подходящего инструмента в текущем состоянии ряда.

1.1.3 Горизонт прогнозирования и постановка one-step / multi-step

В работе рассматриваются режимы прогнозирования с горизонтом $horizon = 1$ и $horizon > 1$. Одношаговый прогноз является наиболее простым случаем: модель использует историю до момента t и предсказывает y_{t+1} . Многошаговый прогноз сложнее, поскольку ошибка на ранних шагах может накапливаться и искажать последующие значения.

Для классических статистических моделей горизонт прогнозирования зачастую реализуется напрямую встроенными средствами библиотеки. Для моделей на лаговых признаках и нейронных сетях возможны как прямой multi-output подход, так и рекурсивная схема с последовательным подставлением ранее спрогнозированных значений. В исследуемом стенде используется единый интерфейс, поддерживающий оба режима, что позволяет сравнивать методы в одинаковой экспериментальной постановке.

1.2 Классические baseline-методы

Классические методы остаются необходимой частью любого корректного сравнительного исследования. Во-первых, они формируют минимальную базу качества, которую должна превосходить более сложная модель. Во-вторых, для коротких и структурированных рядов именно статистические методы часто показывают наилучший результат [1], [2]. В настоящей работе в качестве baseline рассматриваются Naive Forecast, Moving Average, Exponential Smoothing / Holt-Winters, ARIMA и SARIMA.

1.2.1 Naive Forecast, Moving Average и Exponential Smoothing

Naive Forecast является самым простым и при этом крайне важным baseline-методом: прогноз на следующий шаг полагается равным последнему наблюдаемому значению ряда. Несмотря на примитивность, данный подход нередко трудно превзойти на случайных блужданиях и высокошумных данных. Кроме того, именно на основе наивного прогноза удобно рассчитывать масштабирование в метрике MASE [3].

Moving Average строит прогноз на основе локального усреднения последних наблюдений. Его преимуществом является высокая устойчивость к шуму, но при резком тренде или сильной сезонности окно усреднения может вносить систематическое запаздывание. Exponential Smoothing устраняет часть этого недостатка за счет экспоненциального убывания весов, отдавая больший приоритет более свежим наблюдениям [2].

Метод Holt-Winters расширяет экспоненциальное сглаживание, моделируя одновременно уровень, тренд и сезонную компоненту. Благодаря этому он особенно эффективен на рядах типа AirPassengers, где выражена сезонность и наблюдается плавный рост. В то же время при сильной нестационарности или коротких рядах преимущества Holt-Winters могут снижаться из-за нестабильности оценки сезонного профиля.

1.2.2 ARIMA и SARIMA

Модели семейства ARIMA основаны на представлении ряда через

авторегрессионную и скользящую компоненты после применения разностного преобразования [1]. Их сильной стороной является строгая статистическая интерпретация и развитый аппарат диагностики. При корректном подборе параметров ARIMA способна эффективно описывать инерционность ряда и краткосрочные зависимости.

SARIMA добавляет к модели сезонную авторегрессионную и сезонную скользящую структуру. Это делает ее особенно полезной для периодических рядов, где зависимость проявляется не только на соседних шагах, но и через сезонный лаг. Однако подбор порядка модели, проверка стационарности и контроль переобучения требуют аккуратной процедуры валидации.

С точки зрения исследовательского стенда ARIMA/SARIMA представляют важный ориентир. Если RL-подход не способен конкурировать хотя бы с лучшей статистической моделью на компактных датасетах, то его использование должно быть дополнительно обосновано не только качеством, но и адаптивными свойствами.

1.2.3 Область применимости статистических моделей

Статистические методы нередко воспринимаются как устаревшие на фоне современных архитектур глубокого обучения, однако для учебных и прикладных задач малого и среднего масштаба это представление не всегда верно. Если временной ряд относительно короток, а его структура включает выраженный тренд или сезонность, модели экспоненциального сглаживания и SARIMA могут обеспечивать высокое качество прогноза при минимальном времени обучения. Более того, исследователь получает доступ к понятным параметрам модели, диагностике остатков и процедурам проверки адекватности.

Преимущество статистических методов особенно заметно тогда, когда выборка не позволяет обучить сложную нейросетевую модель без существенного риска переобучения. Для MacBook-класса сценариев это означает, что baseline-подходы нельзя рассматривать лишь как формальную точку отсчета. Напротив, именно они часто оказываются основным practically relevant решением, а все более сложные методы должны доказывать не номинальную современность, а фактическое превосходство в контролируемом эксперименте.

Следовательно, при проектировании исследования по теме RL в прогнозировании временных рядов корректно исходить из презумпции силы статистических моделей. RL-надстройка имеет смысл только в том случае, если она способна использовать различия между базовыми методами в изменяющихся режимах ряда, а не просто дублировать выбор уже сильной статической модели.

1.2.4 Ограничения baseline-подходов

Несмотря на перечисленные преимущества, статистические методы имеют и существенные ограничения. Во-первых, их эффективность часто опирается на гипотезы о форме зависимости, например на аддитивность или мультипликативность сезонности. Во-вторых, они хуже переносят сильную нелинейность, взаимодействие нескольких внешних факторов и сложные режимы, в которых структура ряда не сводится к простому тренду и

периодике.

Кроме того, даже если модель Holt-Winters или SARIMA показывает лучшее качество на фиксированном тестовом интервале, это не означает, что она будет оставаться лучшей на всем горизонте эксплуатации системы. Как только в ряде происходит структурный сдвиг, параметры, оцененные по предыдущей истории, перестают быть оптимальными. В полномасштабной промышленной системе это требует регулярного переобучения, а иногда и смены класса модели.

Именно в этой точке появляется исследовательский интерес к RL-подходу. Если базовые модели обладают разными сильными сторонами, то можно попытаться не искать единственный универсальный алгоритм, а построить механизм переключения между ними. Таким образом, ограничения baseline-моделей становятся не только проблемой, но и источником постановки задачи адаптивного выбора.

1.3 Методы машинного обучения

Переход от классических статистических моделей к методам машинного обучения обычно связан с явной генерацией признаков. Вместо прямой подстановки структурных предположений о временном ряде строится обучающая выборка из лагов, скользящих статистик и календарных признаков, после чего прогноз сводится к задаче регрессии.

1.3.1 Лаговые, rolling- и календарные признаки

Лаговые признаки позволяют превратить последовательную задачу в табличную: целевая переменная на шаге t аппроксимируется функцией предыдущих значений $y_{(t-1)}$, $y_{(t-2)}$, ..., $y_{(t-k)}$. К этой группе признаков добавляются rolling mean, rolling std, минимумы и максимумы по окну. Для календарных рядов полезны признаки месяца, дня недели, часа, а также индикаторы начала и конца периода.

Такое представление обладает двумя преимуществами. Во-первых, оно совместимо с широким спектром табличных моделей. Во-вторых, исследователь получает контроль над тем, какая информация доступна модели. Недостаток состоит в том, что качество прогноза начинает зависеть от ручного выбора набора признаков и длины окна, то есть часть задачи переносится на этап feature engineering.

1.3.2 Линейные модели и градиентный бустинг

Линейная регрессия и Ridge Regression удобны как интерпретируемый baseline для табличной постановки. Ridge-регуляризация стабилизирует оценку коэффициентов, особенно при сильной корреляции лагов. В небольших задачах такие модели часто демонстрируют хорошее отношение качества к вычислительной стоимости, хотя слабо описывают сложные нелинейные зависимости.

Градиентный бустинг, в частности LightGBM и CatBoost, способен моделировать нелинейность и взаимодействия признаков [9], [10]. Для временных рядов это особенно полезно, когда влияние сезонности, тренда и локальной волатильности описывается сложной кусочно-нелинейной функцией. Однако бустинг не «понимает» временную структуру сам по себе и целиком опирается на качество сконструированных признаков и

корректность временного разбиения без утечки информации.

В сравнительном исследовании ML-модели занимают промежуточное положение между статистическими и нейросетевыми подходами. Они часто сильнее простых baseline-методов, но остаются легче и дешевле тяжелых нейронных архитектур, что делает их особенно важными для экспериментов в ограниченной вычислительной среде.

1.3.3 Риск утечки данных и временная валидация

Ключевая методическая проблема при использовании табличных моделей в задачах временных рядов состоит в риске утечки информации из будущего. Ошибка может возникнуть не только из-за неправильного train/test split, но и на этапе генерации признаков. Если, например, rolling-статистика строится по окну, в которое случайно попадают будущие значения, модель получает недопустимое преимущество, а итоговая оценка оказывается завышенной.

Поэтому для временных рядов особенно важно различать классическую случайную кросс-валидацию и временную схему оценки. В исследуемом стенде используется именно временная валидация: сперва выбирается обучающий интервал, затем отдельный validation-участок для настройки, а тестовый интервал остается полностью отложенным до финальной проверки. Для multi-step прогнозирования это дополняется rolling-origin логикой, позволяющей имитировать реальные сценарии прогноза во времени.

Методологически это означает, что сравнение ML-моделей должно оцениваться не только по итоговым метрикам, но и по корректности экспериментальной процедуры. В противном случае выигрыш табличной модели может оказаться артефактом ошибочной подготовки данных, а не реальным преимуществом алгоритма.

1.3.4 Интерпретируемость признакового пространства

Одним из достоинств табличной постановки является возможность анализировать вклад признаков. Даже если прогноз формируется сложным бустингом, исследователь все равно может интерпретировать, какие лаги, какие rolling-окна или какие календарные индикаторы оказываются наиболее значимыми. Это особенно полезно в дипломной работе, где требуется не только получить численный результат, но и объяснить механизм принятия решений моделью.

Для ряда с выраженной сезонностью можно ожидать повышенной значимости сезонных лагов, например значения за аналогичный месяц предыдущего периода. Для шумных рядов сильными могут стать признаки локальной дисперсии, сигнализирующие о текущем уровне нестабильности. Таким образом, табличные модели занимают важное место не только как алгоритмы прогноза, но и как инструмент анализа самой структуры данных, на основе которого далее может строиться RL-состояние.

1.4 Нейросетевые методы

Нейросетевые методы прогнозирования временных рядов ориентированы на извлечение сложных временных зависимостей из данных без жестко заданной параметрической структуры. Однако выигрыш в гибкости сопровождается ростом требований к настройке, регуляризации и объему данных.

1.4.1 MLP, LSTM и GRU

Многослойный перцептрон является наиболее прямым развитием табличной постановки: на вход подается окно лагов, а далее нелинейная функция аппроксимируется несколькими полносвязными слоями. MLP прост в реализации и хорошо работает как компактный DL-baseline, но не обладает встроенным механизмом моделирования длинных последовательных зависимостей.

Рекуррентные архитектуры LSTM и GRU специально проектировались для работы с последовательностями. LSTM вводит систему входных, выходных и забывающих ворот, позволяя контролировать поток информации через внутреннее состояние [4]. GRU использует более компактную схему управления памятью, снижая параметрическую сложность [5]. Эти модели способны учитывать порядок наблюдений более естественно, чем MLP, но на коротких рядах и малых вычислительных бюджетах часто не успевают раскрыть свой потенциал.

1.4.2 DLinear и N-BEATS

DLinear относится к классу простых и вычислительно дешевых архитектур для long-term time series forecasting. В основе подхода лежит разложение временного ряда на трендовую и сезонную компоненты с последующей линейной обработкой каждой из них [7]. Практическая ценность DLinear заключается в том, что она обеспечивает сильный baseline при существенно меньшей сложности, чем тяжелые Transformer-модели.

Архитектура N-BEATS предлагает иной взгляд: она использует стек полностью связанных блоков с обратными и прямыми остаточными связями и показала высокое качество на ряде бенчмарков [6]. При этом даже компактная конфигурация N-BEATS способна быть выразительной, но на небольших выборках требует аккуратной регуляризации и ранней остановки.

1.4.3 PatchTST-small как компактная Transformer-модель

В последние годы Transformer-подходы стали важным направлением исследований временных рядов [11], [15]. Однако их прямое применение часто связано с высокой памятью и временем обучения. PatchTST предлагает более экономичную схему: длинная последовательность разбивается на патчи, которые затем обрабатываются как токены [8]. Это уменьшает длину входной последовательности и частично снижает вычислительную стоимость.

Для вычислительно ограниченной среды уместно рассматривать только compact-конфигурацию PatchTST-small и трактовать ее как дополнительный метод, а не как основной. В противном случае сравнение с легкими статистическими моделями становится методически неравномерным из-за слишком различной стоимости обучения.

1.4.4 Компактные конфигурации и регуляризация

При переносе нейросетевых архитектур в дипломное исследование решающую роль начинает играть не максимальная выразительность модели, а баланс между емкостью и устойчивостью. Если задача запускается на ноутбуке с ограниченной памятью и без длительного обучения, то выбор чрезмерно большой сети фактически обесценивает сравнение: модель может

проигрывать не из-за концептуальной слабости, а из-за того, что не была доведена до рабочего режима.

Поэтому в настоящей работе сознательно используются компактные конфигурации. Для MLP ограничивается число скрытых слоев и размер окна, для LSTM и GRU уменьшается скрытая размерность, для N-BEATS сокращается число блоков, а для PatchTST рассматривается only small-конфигурация. Дополнительно применяется early stopping по validation loss, а также фиксируются небольшие значения batch size и числа эпох.

Такая стратегия соответствует реальному инженерному компромиссу. Дипломный проект не должен предполагать наличие дорогостоящей вычислительной инфраструктуры, если задача изначально ориентирована на локальный экспериментальный стенд. Следовательно, сравнение должно строиться между реально исполнимыми конфигурациями, а не между теоретическими максимумами, недоступными в заданной среде.

1.4.5 Сопоставление механизмов последовательного моделирования

Различные нейросетевые архитектуры используют разные способы обработки временной зависимости. MLP опирается на фиксированное окно и не различает внутреннюю структуру последовательности, если она не закодирована самим расположением лагов на входе. LSTM и GRU вводят рекуррентную память, позволяющую последовательно переносить информацию между шагами. DLinear использует линейное разложение трендовой и сезонной компонент, а PatchTST перерабатывает последовательность через механизм self-attention.

Для исследовательской интерпретации важно, что эти различия задают разные индуктивные предположения. Если ряд во многом описывается локальной сезонностью и инерцией, DLinear или SARIMA могут оказаться сильнее глубокой рекуррентной сети. Если полезная информация сосредоточена в сложных нелинейных взаимодействиях, на длинном горизонте преимущества может получить Transformer-подход. Следовательно, разнообразие архитектур в эксперименте оправдано не само по себе, а как попытка покрыть несколько различных способов представления временной зависимости.

1.5 Применение обучения с подкреплением к прогнозированию

1.5.1 RL как механизм выбора модели

Обучение с подкреплением позволяет интерпретировать прогнозирование как последовательность решений. В каждый момент времени агент наблюдает состояние среды и выбирает действие, максимизирующее ожидаемую накопленную награду [12], [14]. В задаче model selection действием может служить выбор одной из заранее обученных моделей прогноза.

Такой подход особенно привлекателен в нестационарной среде. Если лучшая модель меняется во времени, то статический выбор единственного forecasting-алгоритма неизбежно проигрывает хотя бы на части интервала. RL-агент же, в теории, может научиться переключаться между моделями в зависимости от текущего режима ряда, величины последних ошибок и локальной волатильности.

1.5.2 RL как механизм взвешивания ансамбля и корректировки прогноза

Более общий вариант состоит в том, чтобы использовать RL не для дискретного выбора модели, а для выдачи непрерывного вектора весов ансамбля. Такая постановка ближе к actor-critic и PPO-подходам, поскольку действие агента становится непрерывным. Похожая идея представлена в работе по RL-based dynamic model combination, где агент генерирует веса для ансамбля прогнозирующих моделей [16].

Третья возможная схема — корректировка прогноза базовой модели. В этом случае агент не выбирает модель и не задает веса, а вырабатывает поправку к прогнозу, ориентируясь на историю систематических ошибок. Преимуществом такого подхода является меньшая зависимость от числа базовых моделей; недостатком — усложнение reward design и рост риска неустойчивого обучения.

1.5.3 Сравнение с аналогами и ограничения подхода

Применение RL к forecasting-задачам не является универсальным решением. Во-первых, обучение агента само по себе требует ресурсов и дополнительной настройки. Во-вторых, на коротких рядах агент может просто выучить статическую стратегию, не демонстрируя реальной адаптации. В-третьих, если одна из базовых моделей стабильно доминирует на всем интервале, RL-подход не дает выигрыша и лишь повышает вычислительную сложность.

С методической точки зрения поэтому необходимо сравнивать RL не только с «средним» baseline, но и с лучшей отдельной моделью, а также с простым ансамблем. Только такое сравнение позволяет честно ответить на вопрос, дает ли адаптивный агент добавленную ценность или нет.

1.5.4 Reward shaping и устойчивость обучения

Для задач model selection в forecasting-контексте особенно важен выбор функции награды. Если награда определяется только одношаговой абсолютной ошибкой, агент быстро получает плотный сигнал обучения, но при этом оптимизирует в основном локальную реакцию на текущий шаг. Если же использовать более сложную награду, учитывающую накопленную ошибку или штраф за частые переключения между моделями, задача становится ближе к реальной эксплуатационной логике, но обучение может стать менее устойчивым.

С практической точки зрения reward shaping должен учитывать, что резкие переключения между моделями не всегда желательны. В некоторых прикладных системах важна не только точность, но и устойчивость поведения прогнозирующего контура. Поэтому перспективным представляется исследование комбинированных функций награды, где ошибка прогноза является основным компонентом, а частота переключений или чрезмерная variance политики — дополнительными штрафами.

В текущей работе базовой наградой остается отрицательная абсолютная ошибка, поскольку она проще интерпретируется и обеспечивает стабильность в малых датасетах. Однако именно в области reward design лежит один из главных резервов дальнейшего развития RL-подхода к forecasting.

1.5.5 Сценарии оправданного применения RL

Анализ литературы и логики постановки задачи показывает, что RL особенно

оправдан в трех типах сценариев. Первый тип — ряды со сменой режимов, когда в разные периоды времени лучшими оказываются разные модели. Второй — ансамбли, в которых отдельные модели хорошо работают на различных масштабах сезонности, уровнях волатильности или трендовых участках. Третий — ситуации, где модель выбора должна принимать последовательные решения в контуре управления, а не просто выдавать статический прогноз.

Если же исследователь работает с коротким, сравнительно стабильным рядом, то RL-надстройка часто оказывается избыточной. В таком случае лучшая статистическая или табличная модель уже решает задачу с приемлемым качеством и меньшей вычислительной ценой. Следовательно, важным результатом дипломной работы должен быть не только поиск условий успеха RL, но и фиксация условий, в которых его применение нецелесообразно.

1.6 Вывод по разделу

Проведенный обзор показывает, что задача прогнозирования временных рядов требует баланса между качеством, интерпретируемостью и вычислительной стоимостью. Классические статистические методы остаются сильной базой сравнения; ML-подходы на лаговых признаках обеспечивают гибкость при умеренной стоимости; компактные нейросетевые архитектуры позволяют исследовать нелинейные зависимости, но чувствительны к объему данных и настройке.

Обучение с подкреплением представляется перспективным не как безусловная замена forecasting-модели, а как надстройка, управляющая выбором модели или ансамбля в динамике. В то же время исследовательская ценность такого подхода определяется не декларацией адаптивности, а строгим экспериментальным сравнением с более простыми и дешевыми альтернативами. На этой основе во второй главе формулируется постановка задачи и проектируется целевой метод.

2 ПОСТАНОВКА ЗАДАЧИ И ПРОЕКТИРОВАНИЕ МЕТОДА

2.1 Формальная постановка задачи прогнозирования

Пусть задан временной ряд $y_1, y_2, \dots, y_T$, а также, при необходимости, набор внешних признаков x_t . Требуется построить модель f , способную по истории наблюдений оценить будущее значение ряда:

$$y_{(t+h)} = f(y_1, \dots, y_t, x_t),$$

где h — горизонт прогнозирования. В зависимости от метода прогноз может формироваться непосредственно для h шагов вперед либо рекурсивно через последовательную генерацию одношаговых значений.

В настоящей работе используется временное разбиение train/validation/test без перемешивания. Такая схема соответствует реальной постановке forecasting-задачи и исключает утечку информации из будущего. Модель сначала обучается на обучающем интервале, затем на валидации подбираются конфигурации и критерии ранней остановки, после чего финальная оценка проводится на тестовом интервале.

Базовый набор сравниваемых моделей включает статистические методы, модели машинного обучения на лаговых признаках и компактные

нейросетевые архитектуры. Для всех моделей вводится единый интерфейс `fit/predict`, что упрощает сравнительный запуск и последующее использование этих моделей как источников прогнозов для RL-агента.

2.2 Постановка RL-задачи

Пусть имеется M заранее обученных моделей прогноза. На каждом шаге времени t каждая из них выдает прогноз $\hat{y}^{(m)}_t$. Требуется научить агента выбирать модель, прогноз которой следует использовать в текущий момент времени, исходя из локального состояния ряда и истории ошибок.

$s_t = [y_{(t-k+1:t)}, e^{(1)}_{(t-k+1:t)}, \dots, e^{(M)}_{(t-k+1:t)}, \text{mean}_t, \text{std}_t, \text{trend}_t, \hat{y}^{(1)}_t, \dots, \hat{y}^{(M)}_t]$

Здесь $e^{(m)}_t$ обозначает ошибку m -й модели на предыдущих шагах, mean_t и std_t — локальные скользящие статистики, trend_t — индикатор направления изменения ряда, а k — длина окна памяти.

2.2.1 Состояние агента

Состояние должно быть достаточно информативным, чтобы агент мог различать режимы временного ряда. Если использовать только текущие прогнозы моделей, агент не сможет понять, какая из них систематически ошибалась в похожих условиях ранее. Поэтому в состояние включаются не только сами прогнозы, но и последние фактические значения ряда, локальные характеристики вариативности и история ошибок каждой модели.

Выбор конкретного набора признаков состояния является важным проектным решением. Избыточно большое состояние усложняет обучение и увеличивает риск переобучения, особенно на малых датасетах. Слишком бедное состояние, напротив, делает задачу выбора модели почти случайной. В данной работе принят компромиссный набор признаков, пригодный для CPU/MPS-обучения на компактных рядах.

2.2.2 Пространство действий

В дискретной постановке `action space` определяется как:

$a_t \in \{1, 2, \dots, M\}$.

Действие a_t соответствует выбору одной из моделей ансамбля. После выбора агент получает ее прогноз как итоговый прогноз на шаге t . Такая постановка естественным образом соответствует алгоритмам Q-обучения и, в частности, DQN.

Для расширенной постановки с непрерывными весами ансамбля пространство действий можно задать в виде вектора w_t , где сумма весов нормирована. В этом случае более уместны `policy gradient` или `actor-critic` методы, например PPO.

2.2.3 Функция награды

Награда должна напрямую стимулировать снижение ошибки прогноза. В работе рассматриваются две базовые формы:

$r_t = -|y_t - \hat{y}_t|$,

$r_t = -(y_t - \hat{y}_t)^2$.

Первая форма менее чувствительна к выбросам и соответствует интуиции MAE; вторая сильнее штрафует крупные ошибки и ближе к RMSE. В реализованном стенде основной является награда на основе абсолютной ошибки, так как она обеспечивает более устойчивую интерпретацию на

малых выборках и не приводит к чрезмерному доминированию редких выбросов.

2.2.4 Организация эпизода и переходов среды

Важным элементом RL-постановки является структура эпизода. В рассматриваемом варианте один эпизод соответствует последовательному прохождению валидационного или тестового отрезка временной оси. На каждом шаге агент получает новое состояние, выбирает действие, получает награду и переходит к следующему моменту времени. Эпизод завершается при достижении конца выбранного интервала.

Такая схема имеет несколько достоинств. Во-первых, она естественна для временных рядов: агент не перескакивает между независимыми объектами, а проходит реальную последовательность наблюдений. Во-вторых, она позволяет учитывать накопленный эффект неудачных решений, если в будущем будет использована более длинная или *discounted* награда. В-третьих, такая среда легко реализуется в *Gymnasium* и хорошо согласуется с существующими RL-библиотеками.

Одновременно схема эпизодов на компактных датасетах приводит к ограниченному числу шагов взаимодействия, что усложняет обучение. Поэтому при проектировании стенда необходимо искать баланс между реалистичностью среды и достаточным количеством данных для агента.

2.3 DQN-селектор моделей

Основной предлагаемый RL-подход в работе — DQN-агент для выбора модели из ансамбля. Он получает вектор состояния s_t , пропускает его через компактную нейронную сеть и оценивает $Q(s_t, a)$ для каждого допустимого действия a . Далее выбирается действие с максимальным ожидаемым значением возврата.

DQN хорошо подходит для данной постановки по нескольким причинам. Во-первых, пространство действий дискретно и обычно невелико: число базовых моделей составляет порядка 6–10. Во-вторых, сам агент может быть реализован в компактной конфигурации без чрезмерного роста памяти. В-третьих, существующие библиотеки RL позволяют быстро построить воспроизводимый экспериментальный контур.

При этом метод имеет и ограничения. DQN чувствителен к качеству *state representation* и объему данных. На коротких последовательностях агент может не успеть выучить осмысленную политику переключения. Кроме того, если награда определяется только одношаговой ошибкой, агент оптимизирует локальный выбор, а не обязательно долгосрочную стратегию *multi-step* прогнозирования.

2.3.1 Архитектура сети и *replay buffer*

В типичной конфигурации DQN для задачи выбора модели достаточно компактной многослойной сети с несколькими полносвязными слоями. Размер входа определяется размерностью состояния, а размер выхода равен числу доступных моделей ансамбля. Такая архитектура существенно легче классических RL-сетей для визуальных задач и потому подходит для CPU/MPS-сценария.

Важную роль играет *replay buffer*, в который сохраняются переходы вида $(s_t,$

$a_t, r_t, s_{(t+1)}$). Буфер уменьшает корреляцию между соседними наблюдениями при обучении и стабилизирует процесс оптимизации. Однако в задачах временных рядов с малым числом шагов buffer быстро насыщается данными из одного и того же эпизода, поэтому фактическое разнообразие переходов остается ограниченным. Это еще раз подчеркивает, что качество RL-подхода определяется не только алгоритмом, но и богатством самой последовательности данных.

2.3.2 Критерии остановки и выбор контрольной политики

Для практического использования DQN требуется определить момент окончания обучения и способ оценки итоговой политики. В данной работе естественным критерием выступает качество на validation-интервале: агент обучается на последовательности переходов, а затем его политика оценивается без exploration noise на отложенном отрезке.

Контрольная политика должна включать не только самого RL-агента, но и простые сопоставимые альтернативы. В качестве таковых используются: лучшая отдельная модель по validation/test, средний ансамбль прогнозов и, при необходимости, статический выбор модели с минимальной средней ошибкой на validation. Это позволяет отделить вклад собственно RL-адаптации от эффекта обычного подбора хорошего baseline.

2.3.3 Интерпретируемость политики выбора моделей

Хотя DQN относится к классу черных ящиков, в задаче выбора модели его поведение можно интерпретировать значительно проще, чем в задачах управления высокоразмерной физической средой. Пространство действий здесь конечно и невелико, а каждое действие соответствует понятной базовой модели. По этой причине анализ политики может опираться на частоты выбора моделей, последовательности переключений и связь этих переключений с локальными свойствами ряда, например с ростом волатильности или изменением тренда.

С практической точки зрения полезно различать несколько типов поведения агента. Первый тип представляет собой вырождение в статическую политику, когда агент почти всегда выбирает одну и ту же модель. Второй тип соответствует шумовым переключениям без устойчивой связи с качеством прогноза. Третий, наиболее интересный тип, предполагает систематическое переключение между несколькими базовыми моделями в ответ на изменяющиеся режимы ряда. Только в третьем случае можно говорить о содержательной реализации идеи adaptive model selection.

Для интерпретации такой политики в дипломной работе важно анализировать не только итоговые численные метрики, но и траекторию решений во времени. Если агент начинает выбирать сезонную модель на участках с выраженной периодичностью, а более инерционную модель на спокойных интервалах, это служит аргументом в пользу содержательности найденной стратегии даже при умеренном численном выигрыше. Напротив, если выборы агента не коррелируют с изменениями структуры ряда, то даже небольшое улучшение метрик может оказаться случайным.

Дополнительным источником интерпретации является сопоставление действий агента с локальными ошибками всех моделей ансамбля. В этой

логике RL-политика рассматривается как динамическое правило, приближающееся к online-решению задачи expert advice. Такой взгляд полезен потому, что позволяет обсуждать поведение агента на языке сравнения альтернативных моделей, а не только на языке скрытых представлений нейронной сети.

2.4 PPO-подход к взвешиванию ансамбля

В качестве дополнительного направления в работе рассматривается PPO-подход к адаптивному подбору весов ансамбля [13]. Здесь агент вместо дискретного выбора модели генерирует непрерывный вектор весов:

$$w_t = [w_{t,1}, \dots, w_{t,M}], \quad w_{t,m} \geq 0, \quad \sum_m w_{t,m} = 1.$$

Итоговый прогноз формируется как взвешенная сумма прогнозов отдельных моделей. Преимущество такого подхода состоит в большей гибкости: агент может частично использовать сразу несколько источников прогноза. Однако за эту гибкость приходится платить повышенной сложностью настройки, меньшей устойчивостью обучения и большей чувствительностью к масштабу признаков.

В текущем исследовательском стенде основной акцент сделан на DQN-селекторе, а PPO трактуется как расширение архитектуры. Такой выбор обусловлен ограничением вычислительных ресурсов и необходимостью сначала получить корректно работающий дискретный baseline для RL-сравнения.

2.4.1 Ограничения PPO в малых выборках

Хотя PPO считается более устойчивым и универсальным методом по сравнению с рядом других policy-gradient алгоритмов, в задаче компактных временных рядов он сталкивается с собственной проблемой — недостатком разнообразных траекторий. Если длина ряда невелика, а каждая траектория практически повторяет предыдущую, то оценка градиента политики становится шумной и слабо репрезентативной.

Кроме того, непрерывное действие в виде весов ансамбля требует дополнительного контроля нормировки, масштабов признаков и диапазона допустимых корректировок. В результате PPO-подход методически интересен, но в учебной работе должен рассматриваться как расширение базового DQN-сценария, а не как первичный доказательный инструмент. Такая иерархия методов согласуется с целью работы: сначала показать корректность дискретного RL model selector, затем обсуждать более сложные варианты адаптивного ансамблирования.

2.4.2 Сравнение дискретного и непрерывного управления ансамблем

Дискретный выбор модели и непрерывное взвешивание ансамбля отражают две разные философии адаптации. В первом случае предполагается, что в каждый момент времени существует доминирующая модель, прогноз которой достаточно использовать без дальнейшей агрегации. Во втором случае допускается, что ни одна модель не является оптимальной сама по себе, а наилучший прогноз должен формироваться как комбинация нескольких источников.

Преимущество дискретной постановки заключается в ее простоте. Она естественно сочетается с DQN, не требует нормировки весов, легко

интерпретируется и хорошо подходит для малых ансамблей. Однако такой подход может оказаться слишком жестким, если полезная информация действительно распределена между несколькими моделями. В этом случае политика, выбирающая только одну модель, теряет часть потенциального выигрыша, который мог бы быть получен за счет мягкого ансамблирования.

Непрерывное управление ансамблем, напротив, потенциально гибче, но сложнее в реализации и оценке. Возникает вопрос не только о том, как обучить веса, но и о том, как интерпретировать их стабильность, как ограничивать слишком резкие изменения между соседними шагами и как соотносить полученный выигрыш с ростом вычислительной стоимости. Именно поэтому в рамках дипломного исследования разумно рассматривать PPO ensemble weighting как расширение базовой постановки, а не как обязательный центральный компонент.

С исследовательской точки зрения сопоставление этих двух схем важно еще и потому, что оно позволяет разделить задачи выбора и смешивания моделей. Если RL-селектор не дает преимуществ уже на дискретном уровне, преждевременный переход к более сложной непрерывной постановке вряд ли будет методически оправдан. Напротив, если дискретный селектор демонстрирует содержательную реакцию на смену режима, то это создает основу для дальнейшего перехода к более гибким actor-critic схемам.

2.5 Метрики качества и ресурсные ограничения

Для сравнения методов используются метрики MAE, RMSE, MAPE, sMAPE и MASE [3]. Набор выбран таким образом, чтобы оценивать как абсолютную ошибку, так и относительную ошибку, а также получать показатель, сопоставимый между рядами разного масштаба.

MAE удобна для интерпретации в единицах измерения исходного ряда. RMSE сильнее реагирует на крупные промахи и потому полезна в задачах, где важен штраф за большие ошибки. MAPE и sMAPE позволяют оценивать относительное качество, хотя на рядах с малыми значениями должны трактоваться осторожно. MASE полезна как нормализованная мера относительно наивного прогноза.

Помимо ассигасу-метрик в работе анализируются время обучения, время инференса и косвенно вычислительная сложность. Это принципиально важно, поскольку исследование ориентировано на ноутбук с 18 GB RAM и не предполагает использование тяжелых серверных GPU-конфигураций. Следовательно, практическая ценность метода определяется не только ошибкой, но и ценой ее достижения.

2.5.1 Формальное описание метрик

Пусть имеется последовательность истинных значений y_t и прогнозов $\hat{y}_t$ на интервале длины n . Тогда средняя абсолютная ошибка определяется как

$$MAE = (1 / n) * \sum_t |y_t - \hat{y}_t|,$$

а среднеквадратичная ошибка вычисляется по формуле

$$RMSE = \sqrt{(1 / n) * \sum_t (y_t - \hat{y}_t)^2}.$$

Данные метрики характеризуют абсолютное качество прогноза в масштабе исходной переменной. MAE удобна для прямой интерпретации, тогда как

RMSE сильнее штрафует крупные ошибки и потому более чувствительна к редким неудачным прогнозам.

Для относительной оценки используются MAPE и sMAPE. В первом случае метрика показывает среднюю относительную ошибку прогноза:

$$\text{MAPE} = (100 / n) * \sum_t |(y_t - \hat{y}_t) / y_t|.$$

Однако MAPE нестабильна при малых значениях y_t , поэтому в прикладных исследованиях часто рассматривают и симметричную форму:

$$\text{sMAPE} = (100 / n) * \sum_t (2 * |y_t - \hat{y}_t| / (|y_t| + |\hat{y}_t|)).$$

Для междатасетного сравнения в работе дополнительно используется MASE. Ее ключевое достоинство состоит в масштабировании ошибки модели относительно наивного прогноза, что позволяет сравнивать качество на рядах разной размерности:

$$\text{MASE} = \text{MAE}_{\text{model}} / \text{MAE}_{\text{naive}}.$$

Если значение MASE меньше единицы, это означает, что модель превосходит наивный прогноз. Для дипломного исследования такая интерпретация особенно полезна, поскольку позволяет быстро оценивать, окупается ли усложнение метода относительно самого простого baseline.

2.5.2 Вычислительная сложность и ограничения среды

Помимо численных метрик качества в работе учитывается вычислительная цена модели. Для статистических методов основная нагрузка приходится на подбор параметров и повторяющееся переобучение при rolling-origin backtesting. Для табличных методов заметную роль играет генерация признаков и размер окна. Для нейросетевых моделей стоимость определяется числом параметров, размером батча, длиной последовательности и числом эпох. Для RL-компонента добавляется еще и стоимость подготовки panel-данных, обучения политики и взаимодействия со средой.

С практической точки зрения исследование ориентировано на локальную вычислительную среду без обязательного использования дискретного GPU. Это означает, что слишком тяжелые модели заранее выходят за рамки разумной постановки задачи. Следовательно, ресурсное ограничение в данной работе не является внешним неудобством, а входит в саму постановку эксперимента как один из факторов оценки применимости метода.

2.5.3 Критерии практической применимости подхода

Для итоговой интерпретации результатов недостаточно констатировать, что одна модель имеет меньшую ошибку, чем другая. Необходимо также определить, насколько это различие практически значимо в контексте поставленной задачи. Если улучшение MAE оказывается минимальным, но достигается ценой существенного роста времени обучения и усложнения пайплайна, то практическая ценность такого выигрыша может быть низкой.

В рамках работы целесообразно использовать три критерия применимости. Первый критерий связан с качеством прогноза: метод должен либо превосходить лучшую контрольную модель, либо обеспечивать более устойчивое качество на нескольких датасетах. Вторым критерием относится к вычислительной стоимости: время обучения и инференса должно оставаться приемлемым для локального запуска. Третий критерий касается интерпретируемости: желательно, чтобы поведение модели, особенно RL-

агента, можно было содержательно объяснить.

Такой набор критериев особенно важен для дипломной работы, ориентированной не на промышленный рекорд, а на методически корректное исследование. Он позволяет отказаться от формального культа одной метрики и рассматривать полезность метода в более широком инженерном и исследовательском контексте. Именно на этой основе в экспериментальной главе оценивается, где RL действительно может быть оправдан, а где его применение не приводит к существенной добавленной ценности.

2.6 Вывод по разделу

Во второй главе сформулирована единая постановка задачи, в которой прогнозирование временного ряда объединяется с RL-механизмом выбора модели. Показано, что дискретная постановка естественно приводит к DQN-селектору, а непрерывная — к PPO-подходу для взвешивания ансамбля.

Выбранная схема ориентирована на реалистичный режим вычислений и допускает воспроизводимое сравнение с классическими и нейросетевыми baseline-моделями. В следующей главе рассматривается программная реализация соответствующего экспериментального стенда.

3 РЕАЛИЗАЦИЯ ЭКСПЕРИМЕНТАЛЬНОГО СТЕНДА

3.1 Архитектура программного решения

Программный стенд организован как модульный Python-проект с отдельными пакетами для данных, признаков, моделей, RL-компонентов, оценки и утилит. Такое разбиение позволяет изолировать этапы загрузки данных, построения признаков, обучения моделей, backtesting-процедур и визуализации результатов. Внутренняя структура проекта ориентирована на воспроизводимость и расширяемость.

Важным проектным решением является единый интерфейс `fit/predict` для разных классов моделей. Благодаря этому baseline-модели, нейросетевые архитектуры и RL-надстройки можно включать в один экспериментальный пайплайн, не переписывая код сравнения под каждый алгоритм отдельно.

3.1.1 Назначение каталогов проекта

Структура проекта организована таким образом, чтобы логика исследования была прозрачной не только автору, но и внешнему проверяющему. Каталог `data` хранит исходные и подготовленные данные, `notebooks` предназначен для исследовательских заметок и графиков, `src` содержит основной модульный код, `experiments` отвечает за сценарии запуска, а `results` аккумулирует таблицы, прогнозы и визуальные артефакты.

Внутри `src` дополнительно выделяются подпакеты `data`, `features`, `models`, `rl`, `evaluation` и `utils`. Такое разбиение позволяет локализовать ответственность каждого модуля. Например, изменение способа генерации лаговых признаков не затрагивает код RL-среды, а добавление новой метрики не требует переписывания модели. Для дипломной работы это важно еще и потому, что облегчает описание программного решения в текстовой главе и приложении.

3.1.2 Сценарии запуска и роль автоматизации

Повторяемость эксперимента обеспечивается через отдельные runner-скрипты. Один сценарий отвечает за baseline-модели, другой — за нейросетевые архитектуры, третий — за RL model selection, а отдельный

unified benchmark собирает сводные таблицы, графики и markdown-отчет. Такой подход удобен для поэтапной отладки и одновременно позволяет воспроизводить весь цикл исследований одной командой.

Автоматизация особенно важна при сравнении большого числа моделей. Если результаты собираются вручную, высок риск ошибок в сохранении прогнозов, смещения сплитов или потери метрик. В автоматическом пайплайне эти риски снижаются, а сам факт воспроизводимой сборки становится частью качества исследовательского стенда.

3.1.3 Принципы модульности и сопровождения

При проектировании исследовательского программного решения важно учитывать не только текущий набор экспериментов, но и вероятность дальнейшего расширения. По этой причине базовые сущности оформляются в виде модулей с четко определенными интерфейсами. Датасеты описываются через унифицированные загрузчики, модели реализуют единый контракт обучения и прогнозирования, а вычисление метрик вынесено в отдельный блок.

Такое решение уменьшает связность проекта. Добавление новой модели не требует переписывания кода разбиения данных или генерации отчетов; достаточно реализовать адаптер, соответствующий общему интерфейсу. Аналогично, изменение набора метрик не влияет на код самой модели. Для дипломной работы это особенно ценно, поскольку позволяет последовательно наращивать функциональность без разрушения уже проверенных частей стенда.

Отдельное значение имеет документирование кода. Использование type hints, docstrings и предсказуемой структуры каталогов облегчает повторное использование наработок после завершения диплома. В учебно-исследовательском контексте это означает, что программная часть выступает не временной демонстрацией, а полноценным экспериментальным инструментом, пригодным к дальнейшему развитию.

Модульность также напрямую связана с воспроизводимостью. Чем меньше неявных зависимостей между частями проекта, тем проще локализовать источник расхождений в результатах. Это важно как для внутренней верификации автором, так и для внешней проверки руководителем или рецензентом.

3.2 Загрузка и предобработка данных

В стенде используются несколько небольших датасетов временных рядов: AirPassengers, компактный набор stock prices и небольшой weather subset. Такой выбор обусловлен двумя соображениями. С одной стороны, ряды должны быть достаточно разнообразными по структуре. С другой стороны, их объем должен позволять проводить серии экспериментов на локальной машине без обращения к тяжелой инфраструктуре.

Для каждого датасета выполняются одинаковые этапы предобработки: приведение временной метки к единому формату, сортировка по времени, проверка пропусков и временное разбиение train/validation/test без перемешивания. Временное разбиение является обязательным условием корректности forecasting-эксперимента.

3.2.1 Унификация форматов и контроль качества данных

Даже небольшие датасеты часто различаются по формату хранения временных меток, частоте наблюдений и способу задания целевой переменной. Поэтому на этапе подготовки выполняется унификация имен столбцов, преобразование даты ко внутреннему стандарту и явное указание целевого столбца. Это позволяет далее использовать общие функции построения признаков и сравнения моделей.

Отдельное внимание уделяется контролю качества данных. Проверяются пропуски, дубликаты временных меток, нарушения сортировки и аномально короткие интервалы. Для дипломной работы такая проверка важна не только для корректности численных результатов, но и как демонстрация методической добросовестности экспериментальной части.

3.2.2 Работа с короткими рядами и ограничениями выборки

Используемые в работе датасеты не являются большими промышленными корпусами. Это означает, что каждый этап подготовки должен быть особенно аккуратным. Если в длинной последовательности несколько шумных точек могут мало повлиять на итог, то в коротком ряде даже небольшая ошибка подготовки способна радикально исказить оценку модели.

Поэтому в стенде избегаются агрессивные способы очистки данных, которые могут «улучшить» результаты ценой потери реалистичности. Вместо этого акцент делается на прозрачности обработки: ряд сохраняется максимально близким к исходному виду, а все ограничения честно фиксируются в тексте исследования.

3.2.3 Стратегия временного разбиения и контроль утечки

Временное разбиение train/validation/test является одной из центральных гарантий корректности эксперимента. В отличие от обычной табличной задачи, здесь недопустимо перемешивать наблюдения или использовать будущие точки при построении признаков для прошлого. Поэтому разбиение проводится строго вдоль временной оси, а все преобразования выполняются так, чтобы на каждом шаге модели была доступна только историческая информация.

Для проверки отсутствия утечки в стенде используется несколько практических правил. Во-первых, лаговые и rolling-признаки рассчитываются с использованием сдвига, исключающего включение текущей целевой точки. Во-вторых, масштабирование и иные статистические преобразования, если они требуются, оцениваются только на обучающей части и затем применяются к последующим отрезкам. В-третьих, multi-step прогнозирование реализуется без обращения к истинным будущим значениям тестового интервала.

С методической точки зрения такой контроль особенно важен при сравнении простых и сложных моделей. Небольшая утечка может искусственно улучшить результаты нейросетевой или бустинговой модели и создать ложное впечатление превосходства. Поэтому значимым результатом реализации стенда является не только получение метрик, но и обеспечение того, что эти метрики действительно отражают прогнозирование в честной временной постановке.

Дополнительно следует учитывать, что сами длины сплитов влияют на выводы. Слишком короткий тестовый интервал делает оценку шумной, а слишком короткая обучающая часть лишает модели данных для настройки. В дипломной работе используется компромиссное разбиение, обеспечивающее как достаточную длину обучения, так и возможность независимой проверки гиперпараметров на валидационном участке.

3.3 Генерация признаков и baseline-модели

Модуль генерации признаков формирует лаговые признаки, скользящее среднее, скользящее стандартное отклонение и календарные признаки. Такой набор достаточен для сравнения классических ML-моделей и достаточно легок с точки зрения памяти. Все функции снабжаются type hints и docstrings, что повышает читаемость и пригодность к сопровождению.

Baseline-блок включает Naive Forecast, Moving Average, Exponential Smoothing, Holt-Winters, ARIMA, SARIMA, Ridge Regression, LightGBM и, при наличии зависимости, CatBoost. Для всех методов реализовано сохранение прогнозов по сплитам и вычисление стандартного набора метрик.

3.3.1 Преобразование ряда в supervised-постановку

При построении лаговых моделей временной ряд переводится в supervised-форму: для каждого момента времени создается вектор признаков из предыдущих наблюдений и локальных статистик, а целевым значением становится следующее наблюдение или набор наблюдений на горизонте прогнозирования. Такой подход позволяет использовать стандартные регрессионные алгоритмы без изменения их внутренней логики.

Ключевым вопросом является выбор длины окна лагов. Слишком короткое окно лишает модель части исторического контекста, тогда как слишком длинное увеличивает размерность задачи и усиливает риск переобучения. В стенде используются умеренные значения окна, достаточные для демонстрации различий между моделями и совместимые с ограниченной вычислительной средой.

3.3.2 Организация baseline-runner и backtesting

Для честного сравнения статистических и табличных моделей используется единый backtesting-механизм. Каждая модель обучается на обучающем интервале, после чего формирует прогноз на следующем временном участке. Процедура повторяется с rolling-origin логикой, что позволяет приблизить эксперимент к реальному сценарию эксплуатации модели.

Такой подход особенно важен при сравнении моделей с разной стоимостью переобучения. Например, наивный прогноз почти не требует подготовки, тогда как ARIMA и SARIMA нуждаются в более затратной подгонке. Сохранение времени обучения и времени инференса как отдельных метрик позволяет учитывать эту разницу не интуитивно, а количественно.

3.3.3 Поддержка multi-step прогнозирования

Хотя базовый сценарий сравнения в работе сосредоточен на горизонте $horizon = 1$, архитектура стенда предусматривает и поддержку многошагового прогноза. Это важно, поскольку в прикладных задачах часто требуется не только ближайшее следующее значение, но и прогноз на несколько шагов вперед. Реализация такого режима требует аккуратного выбора стратегии

генерации предсказаний и единообразного интерфейса для моделей разных семейств.

Для статистических и нейросетевых моделей возможны как прямой, так и рекурсивный варианты многошагового прогноза. В прямом варианте модель сразу предсказывает вектор длины h . В рекурсивном варианте прогноз строится последовательно, причем ранее сгенерированные значения используются как часть входа для последующих шагов. В стенде применяется практический компромисс: используется подход, наиболее естественный для конкретной модели, но внешне он скрыт за единым методом `predict`.

Поддержка multi-step режима важна и для RL-подхода. Если агент принимает решение только для одношагового прогноза, его стратегия может не переноситься на более длинные горизонты, где накапливается ошибка и возрастает значение устойчивости. Поэтому даже в тех случаях, когда финальные таблицы строятся для $horizon = 1$, сама программная архитектура должна допускать расширение к $horizon > 1$ без переработки базовых модулей.

С инженерной точки зрения такая унификация предотвращает дублирование кода. Один и тот же benchmark-runner может запускать эксперименты с разными горизонтами, а результаты сохраняются в сопоставимом формате. Это облегчает будущую доработку диплома и позволяет при необходимости быстро расширить эмпирическую базу исследования.

3.4 Нейросетевые модели и RL-среда

Нейросетевой блок реализован на PyTorch и включает компактные конфигурации MLP, LSTM, GRU, DLinear, N-BEATS и PatchTST-small. Во всех случаях предусмотрены early stopping по validation loss и автоматический выбор устройства вычислений: `cpu`, `mps` или `cuda`. Для MacBook M3 Pro при наличии поддержки предпочтительно использовать `mps`.

RL-блок состоит из Gymnasium environment, механизма подготовки state/action/reward и агента на базе Stable-Baselines3. Состояние формируется из последних значений ряда, локальных статистик и прогнозов базовых моделей. Сама среда разворачивается вдоль validation/test-оси, что позволяет агенту работать в естественной временной последовательности.

3.4.1 Управление устройством вычислений и ранняя остановка

Поскольку исследование рассчитано на локальный запуск, особое значение имеет механизм выбора вычислительного устройства. Если доступен MPS на macOS, нейросетевые и RL-модули могут использовать его автоматически; при отсутствии — выполняться на CPU. Такой способ организации позволяет не привязывать код к единственной аппаратной платформе.

Не менее важным является early stopping. На малых выборках нейронные модели легко начинают переобучаться уже через несколько эпох, поэтому остановка по validation loss является не просто оптимизацией времени обучения, а обязательным элементом корректной процедуры. Благодаря этому даже компактные сети можно запускать многократно в рамках одного benchmark-сценария.

3.4.2 Специфика RL-пайплайна

RL-сценарий отличается от обычного forecast-runner тем, что здесь необходим промежуточный слой подготовки panel-данных: для каждого шага времени нужно собрать прогнозы всех базовых моделей, историю их ошибок и характеристики самого ряда. Лишь после этого можно сформировать состояние среды и запускать обучение агента.

Фактически RL-блок опирается на результаты уже обученных baseline-моделей. Это важно методически: агент не заменяет forecasting-алгоритм, а надстраивается над ним. Следовательно, оценка RL-подхода должна включать не только его собственную награду, но и качество базовых прогнозов, без которых сама среда не может быть построена.

3.4.3 Разделение стадий обучения базовых моделей и агента

Важной особенностью реализации является отдельность двух уровней обучения. Сначала на обучающей части временного ряда подготавливаются все базовые модели и сохраняются их прогнозы на валидационном и тестовом интервалах. Затем на основе этих прогнозов строится RL-среда, внутри которой агент учится выбирать модель или управлять ансамблем. Такое разделение делает эксперимент логически прозрачным и исключает смешение ролей между forecasting-моделями и управляющей политикой.

Подобная архитектура имеет и практическое преимущество. Прогнозы базовых моделей можно переиспользовать многократно, не переобучая весь ансамбль при каждом новом запуске RL-компонента. Это значительно сокращает вычислительные затраты при отладке награды, состава состояния или гиперпараметров DQN. Для дипломной работы, выполняемой на локальной машине, такая экономия времени особенно важна.

Отдельно следует отметить, что раздельная схема упрощает интерпретацию результатов. Если RL-подход проигрывает лучшей отдельной модели, исследователь может анализировать это как проблему выбора политики, а не как проблему качества самих базовых прогнозов. Аналогично, если один из базовых методов оказывается слабым, его можно исключить из ансамбля и повторно проверить гипотезу без переработки всей программной конструкции.

Таким образом, разделение уровней обучения соответствует и инженерной, и методической логике. Оно делает стенд более управляемым, ускоряет серию экспериментов и повышает прозрачность причинно-следственных связей между качеством базовых моделей и итоговым поведением RL-агента.

3.5 Организация экспериментов и сохранение результатов

Экспериментальный пайплайн организован так, чтобы один runner мог запускать сравнение для нескольких датасетов и разных классов моделей. Для каждого запуска формируются таблицы метрик, CSV-файлы с прогнозами, графики true vs predicted, графики ошибок и сравнительные диаграммы по датасетам.

Итоговые артефакты сохраняются в структуре results/ и дополнительно копируются в папку диплома. Такой подход позволяет использовать одни и те же численные результаты как для технической верификации кода, так и для иллюстрации выводов в тексте работы.

3.5.1 Таблицы, графики и контроль целостности артефактов

В ходе benchmark-запуска формируются несколько типов артефактов: таблицы метрик, прогнозы отдельных моделей, сводные CSV/Excel-файлы, графики true vs predicted, графики ошибок по времени, barplot-диаграммы по метрикам и отдельные визуализации выбора модели RL-агентом. Разделение по типам результатов упрощает последующий анализ и включение материалов в дипломную работу.

Для исследовательской воспроизводимости важно, чтобы имена файлов были однозначно связаны с датасетом, моделью, сплитом и горизонтом прогнозирования. Это правило снижает риск путаницы и позволяет автоматически собирать unified benchmark без ручного переименования артефактов.

3.5.2 Репродуцируемость вычислительного эксперимента

Воспроизводимость обеспечивается не только структурой файлов, но и контролем случайности. Для нейросетевых и RL-модулей фиксируются random seeds, а выбор конфигураций задается явными CLI-параметрами. Такая дисциплина важна, поскольку небольшие изменения начальной инициализации на коротких рядах могут заметно повлиять на результат.

Кроме того, документирование параметров запуска в отдельных гитпеп-скриптах облегчает независимую проверку результатов. В контексте выпускной квалификационной работы это означает, что эксперимент можно не только описать словами, но и повторить в технически близких условиях.

3.5.3 Подготовка материалов для пояснительной записки

Отдельным требованием к экспериментальному стенду является не только получение численных результатов, но и подготовка материалов, пригодных для включения в текст диплома. По этой причине после завершения benchmark-запуска автоматически формируются не только машинно-читаемые CSV-файлы, но и компактные таблицы для вставки в пояснительную записку, а также графики, визуально отражающие ключевые выводы исследования.

Особую роль играют графики true vs predicted и графики ошибок по времени. Первые позволяют визуально сопоставить общую форму траектории прогноза и реального ряда, вторые помогают обнаружить локальные участки, на которых модель систематически недооценивает или переоценивает значения. Для RL-подхода дополнительно строятся графики выбора моделей во времени, поскольку именно они делают возможным содержательный анализ политики агента.

Наличие унифицированного набора визуализаций повышает качество самого текста ВКР. Автор получает возможность опираться не только на итоговую таблицу MAE или RMSE, но и на более глубокий визуальный анализ структуры ошибок. Это особенно важно в ситуации, когда несколько методов дают близкие численные значения, но ведут себя по-разному на отдельных участках ряда.

Таким образом, функция генерации отчетных материалов не является второстепенной надстройкой над кодом. Она интегрирована в сам экспериментальный процесс и служит связующим звеном между

вычислительным стендом и академическим представлением результатов в дипломной работе.

3.6 Вывод по разделу

В третьей главе показано, что предложенный исследовательский стенд может быть реализован как компактное и воспроизводимое программное решение. Принятая архитектура обеспечивает единый интерфейс сравнения моделей, корректную временную валидацию и сохранение артефактов эксперимента. Стенд ориентирован на локальный запуск, что особенно важно для учебно-исследовательской работы. В следующей главе на основе этого стенда анализируются результаты вычислительных экспериментов.

4 ЭКСПЕРИМЕНТАЛЬНОЕ ИССЛЕДОВАНИЕ

4.1 Датасеты и схема эксперимента

В экспериментальной части использованы три компактных временных ряда: `AirPassengers` (144 наблюдения), `stock_prices` (60 наблюдений) и `weather_sample` (48 наблюдений). Эти ряды различаются по частоте, масштабу и характеру динамики, что позволяет проверить устойчивость методов в нескольких режимах: выраженная сезонность, относительно плавный финансовый ряд и короткий погодный ряд.

Для всех датасетов применена единая схема `train/validation/test split` по времени. Сравнение выполнялось в режиме `horizon = 1`, а для нейросетевых и RL-моделей использовались компактные конфигурации и ограниченное число эпох, что соответствует реальному ограничению по памяти и времени обучения на ноутбуке.

4.1.1 Характеристика ряда `AirPassengers`

Ряд `AirPassengers` является классическим примером сезонного временного ряда с выраженным восходящим трендом. Его важное достоинство для дипломной работы заключается в том, что он одновременно достаточно прост для интерпретации и достаточно содержателен для сравнения моделей. Статистические методы с явным учетом сезонности здесь должны вести себя уверенно, что создает сильный `baseline` для RL-сравнения.

С точки зрения постановки задачи этот датасет полезен еще и тем, что позволяет проверить, сможет ли RL-агент распознавать участки, где сезонная структура особенно выражена, а значит выбирать модель с соответствующими индуктивными предпосылками. Если даже на таком хорошо структурированном ряде RL не выигрывает, это само по себе является важным исследовательским выводом.

4.1.2 Характеристика ряда `stock_prices`

Компактный ряд `stock_prices` представляет собой более шумный и менее детерминированный сценарий, чем `AirPassengers`. Для таких данных часто оказывается трудно получить устойчивое преимущество сложных моделей, поскольку значительная часть динамики близка к краткосрочной инерции и локальным случайным колебаниям. Именно поэтому наивный прогноз и простые статистические методы нередко оказываются *surprisingly strong baseline*.

Этот датасет важен для проверки гипотезы о практической полезности RL: если агент способен различать изменения локальной волатильности и

переключаться между моделями, на финансовоподобных рядах это должно проявляться особенно заметно. Если же переключения не происходят или не улучшают ошибку, можно сделать вывод о недостаточной насыщенности state representation или о том, что данные слишком коротки для обучения политики.

4.1.3 Характеристика ряда weather_sample

Weather_sample представляет собой короткий погодный ряд с иной шкалой и иным типом локальной динамики. По сравнению с двумя предыдущими датасетами этот ряд особенно полезен как тест на устойчивость методов при ограниченном объеме данных. Здесь возрастает риск того, что нейросетевые и RL-модели будут страдать не от плохой архитектуры, а от объективного дефицита обучающих наблюдений.

Для дипломной работы такой датасет ценен тем, что демонстрирует нижнюю границу практической применимости сложных методов. Если RL-подход не справляется в этих условиях, это не должно трактоваться как полный провал концепции, но должно быть честно отражено как ограничение исследовательской постановки.

4.1.4 Угрозы внутренней и внешней валидности

При интерпретации результатов необходимо учитывать ограничения экспериментального дизайна. Внутренняя валидность связана с тем, насколько корректно реализованы разбиение данных, генерация признаков, настройка гиперпараметров и процедура сравнения. Для минимизации рисков в работе используется единый пайплайн, одинаковые метрики для всех моделей и строгая временная схема оценки без перемешивания.

Внешняя валидность касается переноса выводов за пределы используемых датасетов. Три компактных ряда позволяют показать принципиальные свойства подходов, но не исчерпывают всего многообразия прикладных сценариев. Поэтому результаты не следует интерпретировать как окончательный вердикт обо всех RL-методах для forecasting-задач. Корректнее рассматривать их как эмпирическое исследование на ограниченном, но методически прозрачном наборе случаев.

Отдельной угрозой валидности является зависимость выводов от компактных конфигураций моделей. Более глубокая настройка нейросетей или использование более длинных рядов могли бы изменить относительные позиции участников сравнения. Однако именно ограничение по вычислительным ресурсам входит в постановку текущей работы. Следовательно, полученные результаты отражают не абстрактно лучший возможный эксперимент, а реалистичный исследовательский сценарий локального запуска.

Такое явное обсуждение ограничений повышает научную добросовестность диплома. Вместо того чтобы скрывать условия, при которых выводы могли бы измениться, работа фиксирует их и тем самым задает направление для дальнейших исследований.

4.2 Сравнение классических методов

На датасете AirPassengers лучшим baseline оказался Holt-Winters с MAE = 13,11 и RMSE = 15,91. SARIMA показала близкий результат с MAE = 13,56.

При этом наивный прогноз и простое экспоненциальное сглаживание дали MAE около 46,36, а Moving Average — 77,55. Такой результат согласуется со структурой ряда: выраженная сезонность и плавный тренд благоприятны для моделей, явно учитывающих сезонную компоненту.

На датасете `stock_prices` лучшей моделью стала ARIMA с $MAE = 0,396$ и $RMSE = 0,558$. Holt-Winters занял второе место с $MAE = 0,460$, а наивный прогноз и простое экспоненциальное сглаживание дали одинаковый результат $MAE = 0,722$. Это показывает, что даже на небольшом ряде статистические методы остаются сильным ориентиром и не должны исключаться из сравнительных исследований.

На датасете `weather_sample` лучшие результаты показали ARIMA и SARIMA: $MAE = 0,113$, $RMSE = 0,134$. Holt-Winters с $MAE = 0,125$ также оказался очень близок к лидерам. Следовательно, для короткого погодного ряда компактные статистические методы в текущей постановке оказались наиболее устойчивыми.

4.2.1 Интерпретация результатов на AirPassengers

Доминирование Holt-Winters и SARIMA на AirPassengers логично с содержательной точки зрения. Ряд обладает структурой, для которой эти модели изначально были предназначены: наблюдается сезонный профиль и плавная долгосрочная динамика. В такой ситуации модель, явно кодирующая сезонность и тренд, получает существенное преимущество перед алгоритмами, которым эти закономерности приходится извлекать неявно.

Важно и то, что превосходство статистических моделей здесь носит не символический, а значительный характер. Разница между MAE порядка 13 и MAE порядка 46–77 показывает, что вопрос выбора класса модели в подобных рядах принципиален. Следовательно, RL-селектор, чтобы быть полезным, должен был бы по крайней мере приблизиться к поведению лучшей сезонной модели, чего в текущем эксперименте не произошло.

4.2.2 Интерпретация результатов на stock_prices

На `stock_prices` статистические модели также сохраняют преимущество, но уже в иной логике. Здесь на первый план выходит не моделирование красивой сезонной структуры, а способность аккуратно использовать локальную инерцию и не переобучаться на шум. ARIMA и Holt-Winters показывают, что компактная модель с умеренной гибкостью может быть эффективнее, чем переусложненный прогнозирующий контур.

Особенно показательно, что RL-селектор не превзошел даже наивный прогноз. Это означает, что агент либо не увидел в состоянии достаточно информативных признаков для переключения, либо сама задача на этом интервале по существу не требовала переключения. Оба варианта важны как исследовательские выводы.

4.2.3 Интерпретация результатов на weather_sample

На коротком `weather_sample` статистические модели снова оказались самыми устойчивыми. Вероятно, это связано с тем, что при малом числе наблюдений простые параметрические предположения оказываются полезнее, чем попытка выучить сложную зависимость из недостаточного объема данных. В этом смысле ряд выступает естественным стресс-тестом против

переусложнения модели.

Для темы диплома здесь особенно значим тот факт, что даже небольшое ухудшение прогноза сразу делает RL-подход методически сомнительным. Если базовый ряд слишком короток, агент учится на слишком ограниченном числе переходов, и сама постановка перестает быть благоприятной для reinforcement learning.

4.2.4 Сопоставление статистических методов между датасетами

Если рассматривать результаты baseline-блока в совокупности, можно заметить важную закономерность. Лидеры меняются между датасетами, однако почти во всех случаях в верхней части рейтинга оказываются именно статистические методы, а не более сложные ML- или DL-подходы. Это означает, что статистический baseline в данной работе не является формальностью; напротив, он задает реальный уровень качества, который необходимо преодолевать всем остальным классам моделей.

Характер лидерства при этом различается. На AirPassengers лучше себя проявляет модель, явно учитывающая сезонность; на stock_prices выигрывает более инерционный и компактный авторегрессионный подход; на weather_sample лучшими становятся методы с умеренной параметрической сложностью. Следовательно, статистический блок демонстрирует не единообразный шаблон, а разнообразие адаптаций к разной структуре рядов. Этот вывод имеет прямое отношение к мотивации RL-подхода. Если бы одна и та же статистическая модель безусловно побеждала на всех датасетах и всех участках временной оси, потребность в адаптивном селекторе была бы минимальной. Однако различие лидеров между рядами показывает, что ансамбль разнородных моделей в принципе содержателен. Другое дело, что на коротких тестовых интервалах RL-агенту оказалось трудно извлечь из этого разнообразия практический выигрыш.

Таким образом, сравнительный анализ статистических методов выполняет двойную функцию. С одной стороны, он задает сильный baseline. С другой стороны, он обосновывает саму постановку задачи динамического выбора, показывая, что разные модели действительно имеют разные зоны компетентности.

4.3 Сравнение ML- и DL-моделей

На AirPassengers лучшей из табличных моделей стал LightGBM с MAE = 35,60, далее следовал Ridge с MAE = 41,44. Обе модели уступили лучшим статистическим подходам, что указывает на важность явного сезонного моделирования для данного ряда. Среди нейросетевых методов лучшим был PatchTST-small с MAE = 99,59, тогда как GRU, DLinear, LSTM, N-BEATS и MLP показали еще более высокую ошибку. Этот результат не означает принципиальной слабости нейронных сетей, но демонстрирует, что на короткой выборке и при жестком ограничении по эпохам статистические модели оказываются предпочтительнее.

На stock_prices Ridge Regression показала MAE = 0,572 и обошла LightGBM, у которого MAE составила 2,020. Нейросетевые архитектуры в этой постановке существенно уступили: MAE находилась в диапазоне примерно от 9,85 у DLinear до 15,60 у MLP. Такой разрыв позволяет сделать вывод, что

на компактных финансовых рядах без дополнительной настройки и без более длинной истории сложные нейронные модели не успевают реализовать свое преимущество.

На `weather_sample` интересный результат показала PatchTST-small: MAE = 0,640, что лучше большинства других нейросетевых моделей, но все же заметно хуже ARIMA и Holt-Winters. Ridge Regression дала MAE = 0,630 и оказалась конкурентоспособной относительно нейросетевого блока. Таким образом, даже когда компактный Transformer ведет себя лучше других DL-методов, он не гарантирует превосходства над хорошо настроенной статистической моделью.

4.3.1 Почему компактные нейросети уступили baseline-моделям

Полученные результаты по ML/DL-блоку не следует интерпретировать упрощенно как доказательство того, что нейросети «хуже» статистических моделей вообще. Более корректное объяснение состоит в сочетании трех факторов: небольшого объема данных, ограниченного бюджета эпох и необходимости использовать компактные конфигурации, пригодные для локального запуска. В таких условиях нейронные сети часто оказываются в невыгодном положении.

Дополнительную роль играет характер самих рядов. `AirPassengers` сильно выигрывает от явного учета сезонности; `stock_prices` близок к сценарию, где инерционные и шумовые свойства ряда доминируют над сложной нелинейной структурой; `weather_sample` слишком короток для надежного обучения глубокой архитектуры. Следовательно, проигрыш DL-моделей в данном исследовании сам по себе является содержательным результатом о границах их практической применимости в легковесной среде.

4.3.2 Роль табличных моделей как промежуточного компромисса

Ridge Regression и LightGBM в ряде случаев показали более содержательные результаты, чем нейросетевые модели. Это подтверждает, что табличная постановка с качественными лаговыми и `rolling`-признаками может служить промежуточным компромиссом между простотой статистических моделей и гибкостью DL-подходов.

Для дипломной темы это важно еще и потому, что именно такие модели удобно включать в ансамбль для RL-селектора. Если все базовые модели либо слишком похожи, либо одинаково слабы, агенту просто нечего выбирать. Табличные методы добавляют в ансамбль отдельный класс индуктивных предпосылок и тем самым делают саму постановку `model selection` более содержательной.

4.3.3 Анализ чувствительности к настройкам и объему данных

Результаты ML- и DL-блока следует рассматривать с учетом того, что производительность этих методов сильно зависит от настройки гиперпараметров и длины обучающей последовательности. Например, увеличение окна лагов может улучшить учет сезонности в Ridge Regression, но одновременно усилить корреляцию признаков и шум. Для LightGBM выбор числа деревьев, глубины и `learning rate` влияет не только на точность, но и на риск переобучения в коротких рядах.

Для нейросетевых архитектур чувствительность еще выше. Размер скрытого

состояния, число блоков, длина входного окна, стратегия нормализации и параметры `early stopping` способны существенно изменить относительный результат. Однако в рамках локального дипломного стенда намеренно используется ограниченный бюджет настройки, так как задача состоит не в поиске глобального рекорда, а в сравнении `practically feasible` конфигураций. Это обстоятельство необходимо учитывать при интерпретации проигрыша нейросетевых моделей. Полученный вывод корректнее формулировать следующим образом: на малых выборках и в компактных конфигурациях DL-модели не показали преимущества над статистическими `baseline`-методами. Такая формулировка точнее отражает исследовательский контекст и не подменяет локальный эксперимент слишком широкими обобщениями. Одновременно чувствительность к настройкам объясняет, почему RL-надстройка может оказаться особенно сложной. Если сами базовые модели сильно зависят от деталей конфигурации, то агент обучается уже над неоднородным и нестабильным ансамблем. Следовательно, качество RL-политики зависит не только от ее собственной настройки, но и от того, насколько разнообразен и надежен набор базовых прогнозов.

4.4 Анализ RL-подхода

В проведенном стендовом исследовании RL-DQN селектор не продемонстрировал устойчивого превосходства над лучшей отдельной моделью. На `AirPassengers` MAE RL-селектора составила 46,25, тогда как у лучшей модели `Holt-Winters` она равнялась 13,11, а у лучшей контрольной `baseline`-модели из RL-блока (`best_single_model`) — 13,56. Средний ансамбль также оказался лучше RL, дав MAE = 27,16.

На `stock_prices` RL-DQN показал MAE = 0,722, то есть фактически совпал с наивным прогнозом и существенно уступил `ARIMA` (0,396) и `Holt-Winters` (0,460). Анализ поведения агента показывает, что на тестовой оси он выбирал только одну модель — `exponential_smoothing` — и не выполнял переключений во времени. Следовательно, адаптивный механизм в данном случае фактически вырождается в статический выбор, не дающий преимущества над лучшей отдельной моделью.

На `weather_sample` RL-DQN дал MAE = 0,913 при MAE = 0,113 у `ARIMA` и `SARIMA`. Агент использовал три различные модели и выполнил два переключения, однако эти переключения не привели к улучшению качества. По-видимому, короткая длина ряда и малая обучающая выборка не позволили агенту выучить надежную стратегию.

Содержательно полученные результаты важны не только как отрицательный итог. Они демонстрируют, что RL-подход должен оцениваться критически. Если одна классическая модель стабильно доминирует на всем интервале, RL-надстройка не только не помогает, но и увеличивает вычислительные затраты. В то же время постановка DQN-селектора остается методически полезной, поскольку формализует задачу динамического выбора модели и создает основу для дальнейших исследований на более длинных и более изменчивых рядах.

4.4.1 Поведение агента по датасетам

Наиболее показательным является анализ выбранных агентом моделей во

времени. Для AirPassengers агент использовал несколько моделей, однако основная масса решений пришлась на `exponential_smoothing`, а единичные переключения на `naive` и `lightgbm` не дали улучшения общей ошибки. Это означает, что политика оказалась не согласована с фактическим лидером тестового интервала, которым был Holt-Winters.

На `stock_prices` поведение агента выродилось в полный статический выбор одной модели. Такое поведение особенно важно с методической точки зрения: оно показывает, что сам факт использования RL не гарантирует адаптивности. Если состояние среды не предоставляет достаточного сигнала о пользе переключения, агент вполне может прийти к тривиальной политике.

На `weather_sample` агент переключался чаще, чем на `stock_prices`, но и это не привело к выигрышу. Следовательно, сами по себе переключения не являются признаком успешности RL. Важен не факт смены модели, а то, соответствует ли эта смена реальному изменению лидера по качеству прогноза.

4.4.2 Что означают отрицательные результаты RL

Отрицательный результат в дипломной работе не является проблемой, если он корректно интерпретирован. В данном случае он позволяет сделать несколько содержательных выводов. Во-первых, для компактных временных рядов RL model selector не может считаться автоматическим улучшением baseline-системы. Во-вторых, успех RL зависит не только от алгоритма, но и от длины ряда, качества ансамбля, информативности состояния и структуры смены режимов.

В-третьих, отрицательный результат помогает сузить область будущих исследований. Вместо абстрактного утверждения о «перспективности RL» работа показывает, что оправданно искать выигрыш прежде всего на более длинных и более нестационарных данных, а также в постановках с richer reward design и более разнообразным набором базовых моделей.

4.4.3 Условия, при которых RL может дать выигрыш

Несмотря на слабые результаты на текущем наборе рядов, сама постановка RL-based model selection не теряет перспективности. Теоретически наибольший выигрыш следует ожидать в тех сценариях, где лидер среди базовых моделей меняется по ходу временной оси, а признаки состояния позволяют эту смену заранее распознавать. Примерами могут служить ряды с чередованием спокойных и высоковолатильных режимов, с эпизодическим разрушением сезонности или с переключением между трендовыми и стационарными участками.

Важным условием является и достаточная длина последовательности. Агенту требуется не только увидеть несколько режимов, но и получить достаточное число повторяющихся ситуаций, чтобы выучить осмысленную политику. На очень коротких рядах даже правильно выбранное состояние и награда могут не компенсировать дефицит взаимодействий со средой. В этом смысле часть неудач RL на compact datasets объясняется не ошибочностью идеи, а статистической сложностью самой задачи обучения политики.

Еще одно условие относится к качеству ансамбля. Если все базовые модели слишком похожи, RL нечего выбирать; если же одна модель доминирует на

всем интервале, селектор опять становится избыточным. Наиболее благоприятна среда, где модели действительно комплементарны и поочередно оказываются лучшими на различных режимах. Следовательно, развитие RL-подхода должно идти параллельно с развитием разнообразного ансамбля базовых forecasting-моделей.

Наконец, существенную роль может сыграть переработка функции награды. Если в reward включить не только одношаговую ошибку, но и устойчивость траектории, штраф за частые бессодержательные переключения либо оценку многошагового выигрыша, агент может лучше согласовывать локальные решения с общей качественной целью системы. Это направление представляется одним из наиболее перспективных для продолжения исследования.

4.5 Сравнение по вычислительным затратам

Среднее время обучения baseline-моделей в тестовом сравнении составило около 0,206 с, нейросетевых моделей — около 0,009 с при очень малом числе эпох, а RL-блока — около 3,625 с. Такая картина требует аккуратной интерпретации. Малое время нейросетевого обучения связано с искусственно ограниченным числом эпох и поэтому не означает, что нейронные модели в общем случае дешевле baseline-подходов. Однако даже при таком ограниченном бюджете RL-подход остается самым затратным по обучению.

По времени инференса все сравниваемые методы в исследуемой постановке остаются достаточно быстрыми, однако именно RL-подход добавляет накладные расходы на подготовку panel-данных и обучение политики. Для небольших рядов и частых переобучений это становится методически значимым ограничением.

С точки зрения практического использования на MacBook M3 Pro с 18 GB RAM наиболее разумным компромиссом выглядят статистические методы и легкие табличные модели. Нейросетевые архитектуры целесообразны как исследовательский компонент и как шаг к более крупным данным, а RL-подход — как механизм адаптации в условиях выраженной смены режима, но не как универсальная замена baseline-моделям.

4.5.1 Практический смысл сравнений по времени

Вычислительная стоимость имеет не только технический, но и методический смысл. Если два метода дают близкое качество, но один из них обучается в десять или двадцать раз дольше, для локального исследовательского контура предпочтение может быть отдано более дешевому алгоритму. Это особенно актуально в дипломной работе, где значительная часть ценности состоит в возможности многократно повторять эксперимент и анализировать результаты.

Для RL-подхода это обстоятельство критично. Даже если бы агент иногда давал небольшой выигрыш по ошибке, необходимо было бы дополнительно оценивать, окупается ли этот выигрыш ростом времени обучения и усложнением пайплайна. Следовательно, сравнение по training time и inference time является не второстепенным украшением benchmark-a, а частью ответа на исследовательский вопрос о практической полезности RL в forecasting.

4.5.2 Баланс качества, сложности и воспроизводимости

Сопоставление вычислительных затрат позволяет по-новому посмотреть на результаты сравнения моделей. В условиях ограниченной среды ценность метода определяется не только тем, насколько мала его ошибка, но и тем, насколько легко этот результат повторить и поддерживать. Простая статистическая модель, которую можно быстро переобучить и заново прогнать на нескольких датасетах, зачастую оказывается более полезной для исследовательского процесса, чем сложная архитектура с нестабильным обучением.

Для нейросетевых и RL-подходов особое значение имеет воспроизводимость. Если метод чувствителен к случайной инициализации, требует многократного перебора гиперпараметров и дает заметно разные результаты между запусками, его практическая применимость в учебно-исследовательском контексте снижается. Поэтому в работе учет времени и организационной сложности выступает естественным дополнением к стандартным метрикам точности.

Именно такой многокритериальный анализ позволяет сделать вывод о том, что на текущем наборе задач RL-селектор не обеспечивает достаточного отношения выигрыш/сложность. Даже если бы локально наблюдалось небольшое улучшение одной из метрик, его следовало бы соотнести с добавленной ценой подготовки ансамбля, построения среды и обучения агента. Этот вывод важен для практической стороны диплома, поскольку показывает, как следует оценивать современные сложные методы в условиях ограниченных ресурсов.

4.6 Итоги экспериментов

Эксперименты показали, что на трех компактных датасетах сильнейшими методами оказались классические статистические подходы. Holt-Winters лидировал на AirPassengers, ARIMA — на stock_prices, ARIMA/SARIMA — на weather_sample. ML-модели на лаговых признаках в ряде случаев давали приемлемое качество, но не превосходили лучшие статистические модели. Нейросетевые модели в условиях ограниченных выборок и малого бюджета эпох уступили baseline-подходам.

Главный вывод по RL-составляющей состоит в том, что в исследуемой постановке DQN model selector не подтвердил гипотезу о практическом выигрыше на компактных рядах. Тем не менее сама формализация задачи через состояние, действие и награду представляется корректной и перспективной для более длинных, более нестационарных рядов и для постановок, где лидер среди базовых моделей действительно меняется во времени.

Таблица 4.1 – Сравнение лучших моделей и RL-DQN на тестовых интервалах

Датасет	Лучшая классическая модель	Лучшая ML/DL модель	RL-DQN, MAE	Вывод
AirPassengers	Holt-Winters, 13,11	LightGBM, 35,60	46,25	RL уступил сезонной модели

stock_prices	ARIMA, 0,396	Ridge, 0,572	0,722	Статический лидер оказался надежнее
weather_sample	ARIMA/ SARIMA, 0,113	Ridge, 0,630	0,913	Короткий ряд не дал агенту преимущества

4.6.1 Обобщение результатов с точки зрения цели исследования

Если соотнести полученные результаты с исходной целью работы, то можно сделать следующий вывод. Работа не доказывает универсальное преимущество RL над классическими и нейросетевыми forecasting-моделями, однако она подтверждает корректность самой постановки RL как адаптивного управляющего слоя над ансамблем. Иными словами, исследование отвечает не утверждением «RL лучше», а более содержательным выводом: RL полезен как концепция адаптации, но его фактическая эффективность определяется структурой данных и качеством базового ансамбля.

Для дипломного исследования такой итог является научно и методически ценным, поскольку он фиксирует границы применимости подхода. Это особенно важно в условиях современного интереса к RL, когда существует соблазн априорно считать его выигрышным решением без достаточно строгого сравнения с простыми baseline-методами.

4.6.2 Ответ на исследовательскую гипотезу

Исходная исследовательская гипотеза работы состояла в том, что обучение с подкреплением может быть полезно не как прямая модель прогноза, а как адаптивный механизм выбора или комбинирования уже обученных прогнозирующих моделей. По итогам проведенных экспериментов эта гипотеза получила частичное подтверждение на концептуальном уровне, но не получила сильного численного подтверждения на выбранных компактных датасетах.

Такой результат важен тем, что он уточняет область применимости гипотезы. Работа показывает, что сама идея RL-надстройки методически состоятельна, однако для ее эмпирического выигрыша необходимы более длинные, более разнообразные и более явно нестационарные ряды, а также ансамбль моделей с выраженной комплементарностью. Следовательно, диплом формирует не окончательный универсальный рецепт, а корректно очерченный исследовательский результат с ясными условиями дальнейшей проверки.

ЗАКЛЮЧЕНИЕ

Выпускная квалификационная работа была посвящена исследованию применения обучения с подкреплением к задаче прогнозирования временных рядов. Основное внимание уделялось не прямой замене forecasting-модели RL-агентом, а построению адаптивного слоя над ансамблем заранее обученных моделей. Такой слой должен принимать решения во времени, выбирая наиболее подходящую модель или, в расширенной постановке, веса ансамбля.

В ходе работы был выполнен аналитический обзор методов прогнозирования временных рядов, охватывающий классические статистические модели, методы машинного обучения на лаговых признаках, компактные нейросетевые архитектуры и RL-подходы. На основе обзора была

сформулирована постановка задачи, в которой состояние агента включает историю ряда, историю ошибок моделей, rolling-статистики, признак тренда и текущие прогнозы ансамбля.

Разработанный экспериментальный стенд обеспечивает воспроизводимое сравнение методов в условиях ограниченных вычислительных ресурсов. В стенде реализованы временное разбиение без перемешивания, генерация признаков, единый интерфейс fit/predict для моделей, сохранение прогнозов, метрик и графиков, а также RL-среда для DQN-селектора.

Результаты экспериментов показали, что на небольших датасетах AirPassengers, stock_prices и weather_sample наилучшее качество обеспечили преимущественно классические статистические методы. RL-DQN селектор в текущей постановке не смог превзойти лучшую отдельную модель и в некоторых случаях оказался хуже даже простого среднего ансамбля. Следовательно, на компактных и сравнительно структурированных рядах применение RL как внешнего селектора не является автоматически оправданным.

Тем не менее работа дает содержательный ответ на поставленный исследовательский вопрос. Проблема, решаемая в работе, состоит в поиске механизма адаптации прогнозирующей системы к изменению структуры временного ряда. Показано, что RL действительно предоставляет корректную формализацию такой адаптации как последовательного процесса принятия решений. Однако практическая полезность подхода проявляется только тогда, когда во временном ряду действительно меняется локальный лидер среди базовых моделей и когда данных достаточно для обучения политики.

К ограничениям исследования относятся компактный размер используемых датасетов, отсутствие полноразмерной PPO-оценки в финальном benchmark-запуске и ограниченный бюджет обучения нейросетевых моделей. Направлениями дальнейшего развития являются: расширение набора датасетов, проведение полноценных экспериментов с PPO ensemble weighting, переход к многошаговым RL-наградам, исследование коррекции прогноза базовой модели агентом, а также изучение online- и continual-learning сценариев для адаптации на более длинных рядах. Таким образом, поставленная цель достигнута, а работа выполнена в полном объеме.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Box G. E. P., Jenkins G. M., Reinsel G. C., Ljung G. M. Time Series Analysis: Forecasting and Control. 5th ed. Hoboken: John Wiley & Sons, 2015.
2. Hyndman R. J., Athanasopoulos G. Forecasting: Principles and Practice. 3rd ed. [Электронный ресурс]. URL: <https://otexts.com/fpp3/> (дата обращения: 27.04.2026).
3. Hyndman R. J., Koehler A. B. Another Look at Measures of Forecast Accuracy // International Journal of Forecasting. 2006. Vol. 22, No. 4. P. 679–688. DOI: 10.1016/j.ijforecast.2006.03.001.
4. Hochreiter S., Schmidhuber J. Long Short-Term Memory // Neural Computation. 1997. Vol. 9, No. 8. P. 1735–1780. DOI: 10.1162/neco.1997.9.8.1735.
5. Cho K., van Merriënboer B., Gulcehre C. et al. Learning Phrase Representations Using RNN Encoder-Decoder for Statistical Machine Translation // EMNLP 2014.

P. 1724–1734. DOI: 10.3115/v1/D14-1179.

6. Oreshkin B. N., Carpov D., Chapados N., Bengio Y. N-BEATS: Neural Basis Expansion Analysis for Interpretable Time Series Forecasting // ICLR 2020.

7. Zeng A., Chen M., Zhang L., Xu Q. Are Transformers Effective for Time Series Forecasting? // AAAI 2023. arXiv:2205.13504.

8. Nie Y., Nguyen N. H., Sinthong P., Kalagnanam J. A Time Series is Worth 64 Words: Long-term Forecasting with Transformers // ICLR 2023. arXiv:2211.14730.

9. Ke G., Meng Q., Finley T. et al. LightGBM: A Highly Efficient Gradient Boosting Decision Tree // Advances in Neural Information Processing Systems. 2017. Vol. 30.

10. Prokhorenkova L., Gusev G., Vorobev A., Dorogush A. V., Gulin A. CatBoost: Unbiased Boosting with Categorical Features // Advances in Neural Information Processing Systems. 2018. Vol. 31.

11. Vaswani A., Shazeer N., Parmar N. et al. Attention Is All You Need // Advances in Neural Information Processing Systems. 2017. Vol. 30.

12. Mnih V., Kavukcuoglu K., Silver D. et al. Human-level Control through Deep Reinforcement Learning // Nature. 2015. Vol. 518. P. 529–533. DOI: 10.1038/nature14236.

13. Schulman J., Wolski F., Dhariwal P., Radford A., Klimov O. Proximal Policy Optimization Algorithms // arXiv preprint arXiv:1707.06347. 2017.

14. Sutton R. S., Barto A. G. Reinforcement Learning: An Introduction. 2nd ed. Cambridge, MA: MIT Press, 2018.

15. Zhou H., Zhang S., Peng J. et al. Informer: Beyond Efficient Transformer for Long Sequence Time-Series Forecasting // Proceedings of the AAAI Conference on Artificial Intelligence. 2021. Vol. 35, No. 12. P. 11106–11115. DOI: 10.1609/aaai.v35i12.17325.

16. Fu Y., Wu D., Boulet B. Reinforcement Learning Based Dynamic Model Combination for Time Series Forecasting // Proceedings of the AAAI Conference on Artificial Intelligence. 2022. Vol. 36, No. 6. P. 6639–6647. DOI: 10.1609/aaai.v36i6.20618.

17. PyTorch Documentation [Электронный ресурс]. URL: <https://pytorch.org/docs/stable/> (дата обращения: 27.04.2026).

18. Gymnasium API Documentation [Электронный ресурс]. URL: <https://gymnasium.farama.org/api/env/> (дата обращения: 27.04.2026).

19. Stable-Baselines3 Documentation. DQN [Электронный ресурс]. URL: <https://stable-baselines3.readthedocs.io/en/master/modules/dqn.html> (дата обращения: 27.04.2026).

20. Stable-Baselines3 Documentation. PPO [Электронный ресурс]. URL: <https://stable-baselines3.readthedocs.io/en/master/modules/ppo.html> (дата обращения: 27.04.2026).

ПРИЛОЖЕНИЕ А

В приложении приведены фрагменты проектной структуры и перечень приложенных артефактов экспериментального стенда.

1) Фрагмент структуры проекта:

data/, notebooks/, src/data/, src/features/, src/models/, src/rl/, src/evaluation/, src/ utils/, experiments/, results/.

2) Логика состояния RL-агента:

`state_t = [last_values, rolling_mean, rolling_std, trend_feature, model_error_history, current_model_predictions]`.

3) Логика действия RL-агента:

`action_t = argmax_a Q(state_t, a)`, где `a` соответствует выбору одной из baseline-моделей.

4) Используемые в дипломной папке графические материалы:

`figures/air_passengers_true_vs_predicted_test.png`

`figures/stock_prices_true_vs_predicted_test.png`

`figures/weather_sample_true_vs_predicted_test.png`

`figures/dataset_comparison_mae_test.png`

`figures/average_training_time_test.png`

`figures/air_passengers_rl_model_choices_test.png`

5) Используемые табличные материалы:

`tables/unified_metrics.csv`

`tables/test_leaderboard.csv`

`tables/rl_control_metrics.csv`

`tables/dataset_overview.csv`

`tables/table_best_models_test.csv`

`tables/table_rl_controls_test.csv`

`tables/table_runtime_by_family.csv`

A.1 Описание использованных датасетов

Датасет `AirPassengers` содержит месячные значения пассажиропотока и используется как эталонный пример ряда с выраженной сезонностью и долгосрочным трендом. Для данного ряда особенно информативно сравнение моделей, учитывающих сезонную структуру явно, и моделей, которые пытаются восстановить ее неявно по лаговым признакам или через нейросетевое представление последовательности.

Датасет `stock_prices` представляет собой компактный набор последовательных значений цены финансового актива. Для него характерны локальная инерция, умеренная шумность и отсутствие столь явной сезонной структуры, как в `AirPassengers`. В рамках дипломной работы этот набор полезен для анализа поведения моделей в условиях, где сильный прогноз может оказаться ближе к `short-term persistence`, чем к явной периодике.

Датасет `weather_sample` содержит короткий погодный ряд. Его исследовательская ценность состоит в том, что он задает жесткое ограничение по объему данных. Именно на таких последовательностях особенно хорошо видны риски переобучения сложных нейросетевых и RL-моделей и преимущества статистических подходов с умеренным числом параметров.

A.2 Конфигурации сравниваемых моделей

Для baseline-моделей использовались стандартные легковесные настройки, достаточные для локального запуска. `Naive Forecast` и `Moving Average` не требуют сложной подгонки. Для `Exponential Smoothing` и `Holt-Winters` параметры подбирались в рамках возможностей библиотеки `statsmodels`. Для `ARIMA` и `SARIMA` использовались компактные порядки модели, пригодные

для малых датасетов и rolling-origin оценки.

Для табличных моделей применялись лаговые, rolling- и календарные признаки. Ridge Regression использовалась как линейный baseline с регуляризацией. LightGBM запускался в CPU-only конфигурации с ограниченным числом деревьев и умеренной глубиной. CatBoost предусмотрен как опциональная модель на случай доступности зависимости, но не являлся обязательной частью минимального сценария.

Нейросетевые модели MLP, LSTM, GRU, DLinear, N-BEATS и PatchTST-small были заданы в компактных конфигурациях. Для всех моделей применялись небольшие размеры скрытых слоев, ограниченное число эпох и early stopping по validation loss. Такой выбор соответствует целям локального исследования и делает эксперимент воспроизводимым на MacBook M3 Pro с 18 GB RAM.

A.3 Параметры RL-среды и агента

RL-среда формировалась на основе сохраненных прогнозов baseline-моделей. В состояние включались последние значения ряда, ошибки каждой модели за несколько предыдущих шагов, rolling mean, rolling std, признак локального тренда и текущие прогнозы всех базовых моделей. Таким образом, агент получал как информацию о поведении самого ряда, так и информацию о недавней успешности альтернативных моделей.

Пространство действий DQN-агента задавалось как дискретное множество моделей ансамбля. На каждом шаге агент выбирал одну модель, прогноз которой использовался как итоговый прогноз. Награда вычислялась по отрицательной абсолютной ошибке, что делало постановку согласованной с MAE-логикой и устойчивой к выбросам.

Для РРО-подхода как расширения предполагалась генерация непрерывного вектора весов ансамбля. Несмотря на то что полноразмерное сравнение РРО не стало центральной частью финального benchmark-a, сама постановка включена в методологическую часть работы как направление дальнейшего развития экспериментального стенда.

A.4Arteфакты экспериментального стенда

В папке figures размещены графики, используемые при интерпретации результатов. К ним относятся: сравнение реальных и прогнозируемых значений на тестовом интервале, междатасетное сравнение моделей по MAE, график среднего времени обучения, а также визуализация выбора моделей RL-агентом для ряда AirPassengers.

В папке tables размещены сводные CSV-файлы с результатами benchmark-a. Они включают полную таблицу метрик по всем моделям, таблицу лидеров на тестовом интервале, таблицу контролей для RL-блока, обзор датасетов, а также дополнительные компактные сводки по лучшим моделям и временным затратам. Эти файлы служат как источником данных для дипломного текста, так и самостоятельным подтверждением воспроизводимости эксперимента.

Помимо итогового DOCX-документа, в папке scripts размещены сценарии сборки диплома и PDF-экспорта. Это позволяет не только читать итоговый документ, но и повторно пересобрать его после редактирования исходного markdown-файла, что важно для дальнейшей доработки выпускной квалификационной работы.

А.5 Перспективы расширения приложения

В дальнейшем приложение может быть дополнено подробными таблицами гиперпараметров, фрагментами исходного кода базовых моделей и RL-среды, а также более развернутыми графиками ошибок по времени для каждого датасета. Для окончательной версии ВКР также целесообразно включить в приложение листинги наиболее важных частей проекта и, при необходимости, дополнительные датасеты либо описание схемы их получения.

А.6 Рекомендуемый состав таблиц для окончательной версии ВКР

Для чистовой версии выпускной квалификационной работы целесообразно включить в приложение полную таблицу метрик по всем моделям и всем датасетам с разделением на *validation* и *test*. Такая таблица позволит читателю самостоятельно сопоставить устойчивость метода между сплитами и проверить, не является ли итоговый лидер следствием случайного удачного тестового интервала.

Отдельная таблица может быть посвящена вычислительным затратам. В нее рекомендуется включить время обучения, время инференса, используемое устройство вычислений, а также краткую характеристику размерности модели, например число параметров для нейросетевых архитектур или порядок модели для ARIMA/SARIMA. Это позволит сделать вывод о практической цене улучшения качества более наглядным.

Для RL-блока полезно дополнительно оформить таблицу с частотами выбора моделей агентом, числом переключений, средней наградой за эпизод и сравнением с лучшей отдельной моделью и средним ансамблем. Такая таблица особенно важна, поскольку делает поведение агента наблюдаемым и облегчает качественную интерпретацию отрицательных и положительных результатов.

А.7 Рекомендуемый состав рисунков для окончательной версии ВКР

Помимо уже подготовленных графиков *true vs predicted* и *barplot*-диаграмм метрик, в итоговую версию ВКР рекомендуется включить графики остатков по времени для лучших моделей каждого семейства. Анализ остатков помогает понять, носят ли ошибки случайный характер или же систематически связаны с отдельными режимами ряда, например с пиками сезонности или фазами повышенной волатильности.

Для RL-части особенно полезны визуализации выбора действий во времени, совмещенные с кривой самого ряда и с кривыми ошибок базовых моделей. Такой рисунок позволяет увидеть, в какие моменты агент предпочитает ту или иную модель и совпадает ли это с фактической локальной успешностью выбранного метода. В дипломной работе именно такие графики создают связь между формальной RL-постановкой и интуитивно понятной логикой поведения системы.

Дополнительно целесообразно включить *learning curves* для нейросетевых моделей и RL-агента. Даже если эти графики не являются центральными для ответа на исследовательский вопрос, они подтверждают корректность настройки процесса обучения и позволяют показать влияние *early stopping*, стабилизации ошибки и возможных признаков переобучения.

А.8 Направления развития программного стенда

Развитие экспериментального стенда может идти по нескольким направлениям. Первое направление связано с расширением набора данных, включая более длинные ряды с ярко выраженной сменой режимов. Второе направление предполагает углубление RL-составляющей: сравнение DQN, PPO, actor-critic схем с рекуррентным состоянием и методов коррекции прогноза базовой модели.

Третье направление касается более строгой автоматизации оценки. В стенд могут быть добавлены процедуры статистического сравнения моделей, например проверка значимости различий в ошибке на нескольких окнах backtesting-a, а также автоматическое формирование LaTeX- или Word-таблиц для пояснительной записки. Это повысит не только удобство использования, но и аналитическую строгость итогового исследования.

Наконец, стенд может быть адаптирован для online-режима, где часть моделей или сам агент дообучаются по мере поступления новых наблюдений. Такой сценарий особенно интересен для темы адаптации к concept drift и может стать естественным продолжением данной выпускной квалификационной работы на уровне магистерского исследования или прикладного проекта.